

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I



BÁO CÁO BÀI TẬP LỚN
KHO DỮ LIỆU VÀ KHAI PHÁ DỮ LIỆU

Giảng viên: ThS. Nguyễn Quỳnh Chi

Nhóm học phần: 03

Danh sách thành viên - Nhóm: 10

Họ và tên	Mã sinh viên
Đỗ Minh Đức	B22DCCN223
Tạ Duy Hiếu	B22DCCN319
Nguyễn Thị Huế	B22DCCN355
Trần Trọng Thái	B22DCCN784
Đinh Quốc Việt	B22DCCN895

Hà Nội, 05/2026

PHÂN CÔNG CÔNG VIỆC

STT	Họ và tên	Mã sinh viên	Công việc
1	Đỗ Minh Đức	B22DCCN223	– Tiền xử lý dữ liệu và xây dựng pipeline preprocessing – Huấn luyện các mô hình Machine Learning – Đánh giá, so sánh và lựa chọn mô hình tối ưu
2	Tạ Duy Hiếu	B22DCCN319	– Xây dựng kiến trúc hệ thống mining và pipeline tự động – Xây dựng cơ chế cập nhật dữ liệu và tái huấn luyện liên tục – Thiết kế giao diện, demo và triển khai hệ thống
3	Nguyễn Thị Huế	B22DCCN355	– Tìm hiểu nghiệp vụ và yêu cầu bài toán – Tổng hợp kết quả đạt được, hạn chế và hướng phát triển của hệ thống – Kết luận, rà soát và hoàn thiện báo cáo
4	Trần Trọng Thái	B22DCCN784	– Nghiên cứu cơ sở lý thuyết về khai phá dữ liệu và bài toán phân loại – Tìm hiểu các mô hình Machine Learning và phương pháp đánh giá – Nghiên cứu cơ chế retraining và cập nhật mô hình
5	Đình Quốc Việt	B22DCCN895	– Thực hiện EDA và thống kê mô tả dữ liệu

			– Phân tích phân phối dữ liệu và trực quan hóa dữ liệu – Đánh giá chất lượng dữ liệu và phát hiện dữ liệu bất thường
6	Cả nhóm		– Thu thập, chuẩn bị dữ liệu và kiểm thử hệ thống

LỜI CẢM ƠN

Trước tiên, chúng em xin gửi lời cảm ơn chân thành đến cô Nguyễn Quỳnh Chi - giảng viên bộ môn, đã dành thời gian xem xét và đánh giá bài báo cáo của nhóm. Sự hướng dẫn và những góp ý quý báu của cô đã giúp chúng em hoàn thiện bài báo cáo này một cách tốt nhất.

Chúng em cũng xin gửi lời cảm ơn đến các thành viên trong nhóm, những người đã cùng nhau hợp tác, đóng góp ý tưởng và nỗ lực hết mình để hoàn thành bài tập. Mỗi người trong nhóm đều có những đóng góp quan trọng, và sự đoàn kết, phối hợp chặt chẽ giữa các thành viên là yếu tố quyết định giúp chúng em hoàn thành công việc này.

Cảm ơn các bạn trong nhóm đã luôn hỗ trợ, chia sẻ và cùng nhau vượt qua mọi thử thách trong suốt quá trình làm việc. Chúng em hy vọng rằng bài báo cáo này sẽ đạt được kết quả tốt, phản ánh công sức mà nhóm đã bỏ ra.

Xin chân thành cảm ơn!

MỤC LỤC

DANH MỤC BẢNG BIỂU

DANH MỤC HÌNH ẢNH

CHƯƠNG 1. TỔNG QUAN VÀ HÌNH THÀNH BÀI TOÁN	1
1.1. Lý do chọn đề tài	1
1.2. Phát biểu bài toán.....	2
1.3. Mục tiêu xây dựng hệ thống	3
<i>1.3.1. Mục tiêu chức năng</i>	<i>3</i>
<i>1.3.2. Mục tiêu kỹ thuật.....</i>	<i>4</i>
<i>1.3.3. Mục tiêu học thuật.....</i>	<i>4</i>
1.4. Phạm vi nghiên cứu.....	5
<i>1.4.1. Phạm vi dữ liệu</i>	<i>5</i>
<i>1.4.2. Phạm vi mô hình.....</i>	<i>5</i>
<i>1.4.3. Phạm vi hệ thống</i>	<i>6</i>
<i>1.4.4. Giới hạn của đề tài.....</i>	<i>6</i>
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CẤU TRÚC MÔ HÌNH.....	8
2.1. Tổng quan về khai quá dữ liệu và bài toán phân loại.....	8
<i>2.1.1. Khái niệm về khai phá dữ liệu</i>	<i>8</i>
<i>2.1.2. Bài toán phân loại.....</i>	<i>9</i>
2.2. Các mô hình học máy sử dụng	11
<i>2.2.1. Mô hình cơ sở: Hồi quy Logistic (Logistic Regression).....</i>	<i>11</i>
<i>2.2.2. Các mô hình học máy nâng cao</i>	<i>13</i>
2.3. Phương pháp đánh giá.....	15
<i>2.3.1. Chiến lược phân chia dữ liệu và huấn luyện chéo</i>	<i>15</i>
<i>2.3.2. Các chỉ số đo lường hiệu năng.....</i>	<i>15</i>
2.4. Cơ chế cập nhật và tái huấn luyện mô hình định kỳ	19
<i>2.4.1. Khởi tạo Hồ sơ dữ liệu.....</i>	<i>20</i>
<i>2.4.2. Pipeline Tái huấn luyện theo lô</i>	<i>20</i>
<i>2.4.3. Đánh giá tự động và Lưu trữ mô hình</i>	<i>21</i>

CHƯƠNG 3. MÔ TẢ VÀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU.....	23
3.1. Giới thiệu bộ dữ liệu	23
<i>3.1.1. Phân loại các biến đặc trưng</i>	<i>23</i>
3.2. Phân tích phân phối (EDA)	25
<i>3.2.1. Thống kê mô tả.....</i>	<i>25</i>
<i>3.2.2. Phân tích phân phối biến mục tiêu và cân bằng lớp.....</i>	<i>26</i>
<i>3.2.3. Trục quan hóa dữ liệu.....</i>	<i>27</i>
<i>3.2.4. Phân tích các biến nhị phân theo nhóm tiểu đường.....</i>	<i>28</i>
<i>3.2.5. Phân tích các biến thứ bậc</i>	<i>29</i>
<i>3.2.6. Phân tích ma trận tương quan.....</i>	<i>30</i>
3.3. Đánh giá chất lượng dữ liệu	32
<i>3.3.1. Kiểm tra giá trị thiếu (Missing Values).....</i>	<i>32</i>
<i>3.3.2. Kiểm tra hàng trùng lặp</i>	<i>32</i>
<i>3.3.3. Phân tích ngoại lai (Outlier Detection)</i>	<i>32</i>
<i>3.3.4. Kiểm tra tính nhất quán dữ liệu.....</i>	<i>34</i>
3.4. Nhận xét rút ra từ phân tích EDA.....	34
CHƯƠNG 4. TIỀN XỬ LÝ DỮ LIỆU.....	36
4.1. Mục tiêu tiền xử lý.....	36
4.2. Các bước tiền xử lý.....	36
<i>4.2.1. Làm sạch dữ liệu.....</i>	<i>37</i>
<i>4.2.2. Chuẩn hóa và biến đổi dữ liệu</i>	<i>38</i>
<i>4.2.3. Xử lý mất cân bằng dữ liệu</i>	<i>39</i>
CHƯƠNG 5. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH	42
5.1. Môi trường huấn luyện.....	42
<i>5.1.1. Phần cứng và phần mềm.....</i>	<i>42</i>
<i>5.1.2. Thư viện sử dụng.....</i>	<i>42</i>
5.2. Huấn luyện mô hình.....	43
5.3. Đánh giá kết quả.....	44

5.4. So sánh và lựa chọn mô hình.....	47
CHƯƠNG 6. XÂY DỰNG HỆ THỐNG MINING.....	49
6.1. Kiến trúc hệ thống.....	49
6.1.1. Sơ đồ kiến trúc tổng thể.....	49
6.1.2. Vai trò của từng tầng.....	50
6.2. Lấy dữ liệu và tiền xử lý tự động	51
6.2.1. Cơ chế thu nhận dữ liệu.....	51
6.2.2. Kiểm tra cấu trúc và phát hiện trôi dữ liệu	52
6.2.3. Quy trình tiền xử lý tự động.....	52
6.3. Hệ thống cập nhật và tái huấn luyện liên tục	53
6.3.1. Ba cơ chế kích hoạt tái huấn luyện	53
6.3.2. Quy trình ra quyết định Champion – Challenger	53
6.3.3. Quản lý phiên bản và truy vết	55
CHƯƠNG 7. GIAO DIỆN VÀ DEMO.....	56
7.1. Tổng quan giao diện.....	56
7.2. Trang Dự đoán	56
7.3. Trang Quản trị và Tái huấn luyện	58
7.4. Trang So sánh và Demo.....	60
7.5. Kịch bản triển khai và kiểm thử.....	62
KẾT LUẬN 64	
1. Kết quả đạt được.....	64
2. Hạn chế.....	64
3. Hướng phát triển.....	65

DANH MỤC BẢNG BIỂU

Bảng 3.1. Phân loại 22 biến đặc trưng theo nhóm chức năng.	23
Bảng 3.2. Thống kê mô tả các biến số trong tập dữ liệu.	25
Bảng 3.3. So sánh tỉ lệ xuất hiện biến nhị phân giữa hai nhóm.	28
Bảng 3.4. Kết quả phân tích ngoại lai theo phương pháp IQR.	33
Bảng 4.1. Tóm tắt kết quả kiểm tra chất lượng dữ liệu.	37
Bảng 4.2. So sánh hai phương pháp chuẩn hóa và lý do lựa chọn.	39
Bảng 4.3. Tóm tắt thông tin phân phối nhãn trong bộ dữ liệu sử dụng.	41
Bảng 5.1. Danh sách thư viện sử dụng trong thực nghiệm.	42
Bảng 5.2. Không gian tìm kiếm siêu tham số và kết quả GridSearchCV.	43
Bảng 5.3. Kết quả đánh giá các mô hình trên tập kiểm thử ($n = 14.139$).	44
Bảng 5.4. Chi tiết ma trận nhầm lẫn (Confusion Matrix) của từng mô hình.	45

DANH MỤC HÌNH ẢNH

Hình 3.1. Phân bố biến mục tiêu Diabetes_binary.	26
Hình 3.2. Histogram và Boxplot so sánh BMI giữa nhóm có và không có tiểu đường.	27
Hình 3.3. Tỷ lệ (%) các đặc trưng nhị phân theo nhóm tiểu đường.	28
Hình 3.4. Phân phối các biến thứ bậc theo nhóm tiểu đường.	29
Hình 3.5. Ma trận tương quan Pearson giữa 22 biến trong tập dữ liệu.	30
Hình 3.6. Hệ số tương quan Pearson của từng đặc trưng với biến mục tiêu Diabetes_binary.	31
Hình 3.7. Boxplot phân tích ngoại lai cho BMI, Sức khỏe tâm thần và Sức khỏe thể chất.	33
Hình 6.1. Kiến trúc hệ thống dự đoán nguy cơ bệnh tiểu đường.	49
Hình 6.2. Quy trình ra quyết định Champion - Challenger.	54
Hình 7.1. Giao diện trang Dự đoán – nhóm Sức khỏe nền và Lối sống.	57
Hình 7.2. Kết quả dự đoán cho kịch bản “Cao tuổi, nguy cơ cao”.	58
Hình 7.3. Trang Quản trị – Thẻ Champion với bảng xếp hạng năm mô hình.	59
Hình 7.4. Trang So sánh và Demo với hai kịch bản demo được mở rộng.	62

CHƯƠNG 1. TỔNG QUAN VÀ HÌNH THÀNH BÀI TOÁN

1.1. Lý do chọn đề tài

Bệnh tiểu đường hiện nay là một trong những bệnh mãn tính phổ biến và có tốc độ gia tăng nhanh trên toàn thế giới. Đây là căn bệnh nguy hiểm do thường tiến triển âm thầm trong thời gian dài và khó được phát hiện ở giai đoạn sớm. Nếu không được chẩn đoán và điều trị kịp thời, bệnh có thể dẫn đến nhiều biến chứng nghiêm trọng như tim mạch, đột quỵ, suy thận, tổn thương thần kinh và giảm chất lượng cuộc sống của người bệnh. Vì vậy, việc phát hiện sớm nguy cơ mắc bệnh tiểu đường có ý nghĩa đặc biệt quan trọng trong công tác chăm sóc và bảo vệ sức khỏe cộng đồng.

Trong bối cảnh hiện nay, cùng với sự phát triển của công nghệ thông tin và hệ thống lưu trữ dữ liệu, lượng dữ liệu y tế được thu thập ngày càng lớn và đa dạng. Các dữ liệu này chứa nhiều thông tin giá trị liên quan đến tình trạng sức khỏe, thói quen sinh hoạt và các yếu tố nguy cơ của bệnh nhân. Điều này tạo điều kiện thuận lợi cho việc áp dụng các kỹ thuật khai phá dữ liệu (Data Mining) và học máy (Machine Learning) nhằm phân tích dữ liệu và hỗ trợ dự đoán bệnh. So với các phương pháp thống kê truyền thống, các mô hình học máy có khả năng phát hiện các mẫu dữ liệu tiềm ẩn, học được mối quan hệ phức tạp giữa các đặc trưng và đưa ra dự đoán với độ chính xác cao hơn.

Bên cạnh giá trị học thuật, bài toán dự đoán nguy cơ mắc bệnh tiểu đường còn có tính ứng dụng thực tiễn cao. Hệ thống dự đoán có thể được sử dụng như một công cụ hỗ trợ ra quyết định trong lĩnh vực y tế, giúp bác sĩ và người dùng đánh giá sớm nguy cơ mắc bệnh dựa trên các chỉ số sức khỏe. Ngoài ra, việc xây dựng hệ thống mining kết hợp cơ chế cập nhật và tái huấn luyện mô hình định kỳ còn giúp hệ thống có khả năng thích nghi với dữ liệu mới, nâng cao tính ổn định và khả năng triển khai thực tế.

Trong đề tài này, nhóm sử dụng bộ dữ liệu BRFSS (Behavioral Risk Factor Surveillance System) năm 2015 về các chỉ số sức khỏe liên quan đến bệnh tiểu đường. Đây là bộ dữ liệu thực tế có kích thước lớn, được thu thập từ khảo sát sức khỏe cộng đồng, bao gồm nhiều thuộc tính phản ánh tình trạng sức khỏe và hành vi sinh hoạt của người dân. Với quy mô dữ liệu lớn, tính đa dạng và độ tin cậy cao, bộ dữ liệu BRFSS phù hợp để nghiên cứu, xây dựng và đánh giá các mô hình học máy trong bài toán dự đoán nguy cơ mắc bệnh tiểu đường.

Từ những lý do trên, nhóm quyết định lựa chọn đề tài “Xây dựng hệ thống phân loại dự đoán nguy cơ mắc bệnh tiểu đường và triển khai quy trình huấn luyện liên tục” nhằm nghiên cứu và ứng dụng các kỹ thuật khai phá dữ liệu, học máy vào lĩnh vực chăm sóc sức khỏe, đồng thời xây dựng nền tảng cho các hệ thống hỗ trợ chẩn đoán thông minh trong tương lai.

1.2. Phát biểu bài toán

Trong bối cảnh số lượng người mắc bệnh tiểu đường ngày càng gia tăng, nhu cầu xây dựng các hệ thống hỗ trợ dự đoán nguy cơ mắc bệnh dựa trên dữ liệu sức khỏe ngày càng trở nên cần thiết. Với sự phát triển của khai phá dữ liệu và học máy, các mô hình dự đoán có khả năng hỗ trợ phát hiện sớm nguy cơ mắc bệnh thông qua việc phân tích các đặc trưng liên quan đến tình trạng sức khỏe và lối sống của người dùng.

Trong đề tài này, dữ liệu đầu vào bao gồm các đặc trưng sức khỏe và hành vi sinh hoạt được thu thập từ bộ dữ liệu BRFSS 2015, chẳng hạn như chỉ số khối cơ thể (BMI), huyết áp cao (HighBP), cholesterol cao (HighChol), mức độ hoạt động thể chất (PhysActivity), độ tuổi (Age), tình trạng sức khỏe tổng quát (GenHlth), thu nhập (Income), trình độ học vấn (Education) cùng nhiều thuộc tính khác có liên quan đến nguy cơ mắc bệnh tiểu đường.

Biến mục tiêu của bài toán là thuộc tính `Diabetes_binary`, trong đó:

- Giá trị 0 biểu thị người không mắc bệnh tiểu đường.
- Giá trị 1 biểu thị người mắc bệnh tiểu đường.

Dựa trên đặc điểm của bộ dữ liệu và yêu cầu của bài toán, đề tài được xác định thuộc bài toán phân loại nhị phân (Binary Classification) trong lĩnh vực học máy có giám sát (Supervised Learning). Mô hình học máy được huấn luyện trên tập dữ liệu đã có nhãn nhằm học các đặc trưng và mối quan hệ giữa các yếu tố sức khỏe với tình trạng mắc bệnh tiểu đường.

Thông qua quá trình huấn luyện, mô hình có khả năng phân loại một đối tượng vào một trong hai nhóm: mắc bệnh hoặc không mắc bệnh tiểu đường dựa trên các chỉ số sức khỏe và hành vi sinh hoạt đầu vào. Kết quả dự đoán của mô hình được sử dụng để hỗ trợ đánh giá nguy cơ mắc bệnh, góp phần hỗ trợ quá trình sàng lọc và phát hiện sớm bệnh tiểu đường.

1.3. Mục tiêu xây dựng hệ thống

Đề tài hướng đến việc xây dựng một hệ thống hỗ trợ dự đoán nguy cơ mắc bệnh tiểu đường dựa trên các kỹ thuật khai phá dữ liệu và học máy. Hệ thống được thiết kế nhằm đáp ứng cả mục tiêu chức năng, mục tiêu kỹ thuật và mục tiêu nghiên cứu học thuật.

1.3.1. Mục tiêu chức năng

Đề tài hướng đến xây dựng một hệ thống hỗ trợ dự đoán nguy cơ mắc bệnh tiểu đường dựa trên các kỹ thuật khai phá dữ liệu và học máy. Hệ thống cần có khả năng thực hiện toàn bộ quy trình xử lý dữ liệu từ giai đoạn phân tích, tiền xử lý đến huấn luyện và đánh giá mô hình một cách tự động và có hệ thống.

Trước hết, hệ thống phải hỗ trợ phân tích và khám phá dữ liệu sức khỏe từ bộ dữ liệu đầu vào nhằm xác định các đặc trưng quan trọng có ảnh hưởng đến nguy cơ mắc bệnh tiểu đường. Quá trình này bao gồm việc thống kê mô tả dữ liệu, phân tích phân phối và trực quan hóa dữ liệu để hỗ trợ hiểu rõ đặc điểm của tập dữ liệu nghiên cứu.

Bên cạnh đó, hệ thống cần thực hiện các bước tiền xử lý dữ liệu như làm sạch dữ liệu, chuyển đổi kiểu dữ liệu và chuẩn hóa dữ liệu nhằm đảm bảo chất lượng dữ liệu đầu vào phục vụ cho quá trình huấn luyện mô hình học máy. Việc xây dựng pipeline tiền xử lý giúp đảm bảo tính nhất quán và khả năng tái sử dụng trong các lần huấn luyện tiếp theo.

Ngoài chức năng xử lý dữ liệu, hệ thống cần hỗ trợ huấn luyện nhiều mô hình học máy khác nhau phục vụ bài toán phân loại nhị phân. Sau quá trình huấn luyện, hệ thống thực hiện đánh giá và so sánh hiệu năng giữa các mô hình dựa trên các chỉ số đánh giá phù hợp nhằm lựa chọn mô hình tối ưu cho bài toán dự đoán nguy cơ mắc bệnh tiểu đường.

Hệ thống đồng thời cần có khả năng tự động lưu trữ mô hình, kết quả thực nghiệm và metadata của quá trình huấn luyện để phục vụ việc tái sử dụng và quản lý mô hình. Ngoài ra, đề tài còn hướng đến xây dựng cơ chế hỗ trợ cập nhật dữ liệu và tái huấn luyện mô hình định kỳ nhằm đảm bảo khả năng thích nghi của hệ thống khi có dữ liệu mới phát sinh trong thực tế.

1.3.2. Mục tiêu kỹ thuật

Bên cạnh mục tiêu chức năng, đề tài còn hướng đến việc xây dựng hệ thống đáp ứng các yêu cầu kỹ thuật liên quan đến hiệu năng xử lý, khả năng mở rộng và tự động hóa quy trình khai phá dữ liệu.

Hệ thống cần có khả năng xử lý hiệu quả bộ dữ liệu BRFSS với quy mô hơn 70.000 mẫu dữ liệu và nhiều thuộc tính sức khỏe khác nhau. Quá trình xử lý và huấn luyện mô hình phải đảm bảo tính ổn định, đồng thời tối ưu thời gian thực thi và khả năng sử dụng tài nguyên tính toán.

Một mục tiêu quan trọng khác là tự động hóa toàn bộ pipeline từ bước đọc dữ liệu, tiền xử lý, huấn luyện, đánh giá mô hình đến lưu trữ kết quả thực nghiệm. Việc tự động hóa giúp giảm sự can thiệp thủ công, tăng khả năng tái lập thực nghiệm và hỗ trợ mở rộng hệ thống trong tương lai.

Ngoài ra, hệ thống cần hỗ trợ khả năng cập nhật dữ liệu mới và tái huấn luyện mô hình mà không cần xây dựng lại toàn bộ quy trình xử lý. Các mô hình sau khi huấn luyện phải được lưu trữ dưới dạng có thể tái sử dụng trong các lần dự đoán tiếp theo hoặc triển khai thực tế.

Đề tài cũng hướng đến việc sinh tự động các báo cáo đánh giá mô hình, lưu trữ kết quả thực nghiệm và metadata nhằm phục vụ cho quá trình phân tích, so sánh và quản lý kết quả nghiên cứu.

1.3.3. Mục tiêu học thuật

Về mặt học thuật, đề tài tập trung nghiên cứu và so sánh hiệu quả của nhiều thuật toán học máy khác nhau trong bài toán dự đoán nguy cơ mắc bệnh tiểu đường. Các mô hình được lựa chọn bao gồm Logistic Regression, Decision Tree, Random Forest, Gradient Boosting và K-Nearest Neighbors (KNN). Đây là các thuật toán phổ biến trong lĩnh vực khai phá dữ liệu và phân loại dữ liệu y tế.

Thông qua quá trình thực nghiệm, đề tài tiến hành đánh giá khả năng dự đoán của từng mô hình trên cùng một tập dữ liệu nhằm xác định mô hình phù hợp nhất cho bài toán nghiên cứu. Việc so sánh được thực hiện dựa trên nhiều chỉ số đánh giá khác nhau như Accuracy, Precision, Recall, F1-score, ROC-AUC và Confusion Matrix nhằm đảm bảo đánh giá toàn diện hiệu năng mô hình.

Bên cạnh việc đánh giá độ chính xác, đề tài còn tập trung phân tích mức độ ảnh hưởng của các đặc trưng đầu vào thông qua phương pháp Feature Importance. Kết quả phân tích giúp xác định các yếu tố sức khỏe có ảnh hưởng lớn đến nguy cơ mắc bệnh tiểu đường, từ đó hỗ trợ quá trình giải thích mô hình và nâng cao giá trị ứng dụng thực tiễn của hệ thống.

Ngoài ra, đề tài cũng phân tích ưu điểm, hạn chế và khả năng ứng dụng của từng thuật toán trong bối cảnh dữ liệu y tế nhằm làm cơ sở cho việc lựa chọn mô hình phù hợp trong các hệ thống hỗ trợ dự đoán bệnh lý trong tương lai.

1.4. Phạm vi nghiên cứu

Để đảm bảo tính tập trung, khả năng triển khai và phù hợp với phạm vi của đề tài môn Khai phá dữ liệu, nhóm xác định phạm vi nghiên cứu bao gồm các nội dung sau.

1.4.1. Phạm vi dữ liệu

Đề tài sử dụng bộ dữ liệu BRFSS 2015 Diabetes Health Indicators làm nguồn dữ liệu chính cho quá trình nghiên cứu, phân tích và thực nghiệm. Đây là bộ dữ liệu khảo sát sức khỏe cộng đồng có quy mô lớn, bao gồm nhiều thuộc tính liên quan đến tình trạng sức khỏe, thói quen sinh hoạt và nguy cơ mắc bệnh tiểu đường của người tham gia khảo sát.

Các thuộc tính được sử dụng trong nghiên cứu bao gồm các chỉ số như huyết áp cao (HighBP), cholesterol cao (HighChol), chỉ số BMI, hoạt động thể chất (PhysActivity), sức khỏe tổng quát (GenHlth), độ tuổi (Age), thu nhập (Income), trình độ học vấn (Education) cùng nhiều đặc trưng khác có liên quan đến nguy cơ mắc bệnh tiểu đường.

Bộ dữ liệu sau khi xử lý gồm khoảng 70.000 mẫu dữ liệu và được sử dụng cho các bước phân tích khám phá dữ liệu, tiền xử lý, huấn luyện và đánh giá mô hình học máy.

1.4.2. Phạm vi mô hình

Đề tài tập trung nghiên cứu các thuật toán học máy có giám sát (Supervised Learning) phục vụ bài toán phân loại nhị phân trong lĩnh vực dự đoán nguy cơ mắc bệnh tiểu đường. Các mô hình được lựa chọn bao gồm:

- Logistic Regression

- Decision Tree
- Random Forest
- Gradient Boosting
- K-Nearest Neighbors (KNN)

Các mô hình trên được sử dụng nhằm đánh giá khả năng học dữ liệu, so sánh hiệu năng và lựa chọn thuật toán phù hợp nhất cho bài toán dự đoán bệnh tiểu đường.

Trong phạm vi nghiên cứu của đề tài, nhóm không triển khai các phương pháp học sâu (Deep Learning) hoặc các mô hình trí tuệ nhân tạo phức tạp khác do yêu cầu tài nguyên tính toán lớn, thời gian huấn luyện cao và chưa thực sự cần thiết đối với cấu trúc của bộ dữ liệu hiện tại.

1.4.3. Phạm vi hệ thống

Hệ thống được xây dựng theo hướng hỗ trợ khai phá dữ liệu và huấn luyện mô hình học máy trên môi trường offline. Quy trình xử lý dữ liệu và huấn luyện mô hình được thực hiện theo cơ chế batch-based, tức dữ liệu được xử lý theo từng đợt thay vì xử lý liên tục theo thời gian thực.

Đề tài tập trung xây dựng pipeline gồm các bước: đọc dữ liệu, tiền xử lý, huấn luyện mô hình, đánh giá kết quả, lưu trữ mô hình và hỗ trợ tái huấn luyện khi có dữ liệu mới. Ngoài ra, hệ thống còn hỗ trợ sinh báo cáo kết quả và lưu metadata phục vụ cho việc quản lý thực nghiệm.

Trong phạm vi hiện tại, hệ thống chưa triển khai trên môi trường production hoặc nền tảng điện toán đám mây (cloud), đồng thời chưa tích hợp cơ chế xử lý dữ liệu thời gian thực (real-time processing).

1.4.4. Giới hạn của đề tài

Mặc dù đạt được khả năng dự đoán nguy cơ mắc bệnh tiểu đường dựa trên dữ liệu sức khỏe, hệ thống được xây dựng trong đề tài chỉ mang tính chất hỗ trợ tham khảo và nghiên cứu học thuật. Kết quả dự đoán của mô hình không có giá trị thay thế bác sĩ, chuyên gia y tế hoặc các phương pháp chẩn đoán lâm sàng chuyên sâu.

Độ chính xác của mô hình phụ thuộc vào chất lượng dữ liệu đầu vào, phạm vi đặc trưng được sử dụng cũng như tính đại diện của bộ dữ liệu nghiên cứu. Ngoài ra, dữ liệu

BRFSS chủ yếu dựa trên khảo sát cộng đồng nên vẫn có khả năng tồn tại sai số chủ quan từ người tham gia khảo sát.

Bên cạnh đó, hệ thống hiện mới tập trung vào bài toán phân loại nguy cơ mắc bệnh tiểu đường mà chưa mở rộng sang các bài toán dự đoán biến chứng, phân loại mức độ bệnh hoặc hỗ trợ điều trị cá nhân hóa. Đây sẽ là những hướng phát triển tiềm năng trong tương lai.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CẤU TRÚC MÔ HÌNH

2.1. Tổng quan về khai phá dữ liệu và bài toán phân loại

2.1.1. Khái niệm về khai phá dữ liệu

a. Định nghĩa và bản chất

Khai phá dữ liệu là bước cốt lõi trong toàn bộ quy trình Khám phá tri thức từ cơ sở dữ liệu (Knowledge Discovery in Databases - KDD). Bản chất của khai phá dữ liệu không đơn thuần là việc trích xuất hay tìm kiếm dữ liệu thông thường, mà là quá trình phân tích một lượng lớn dữ liệu thô để tự động (hoặc bán tự động) phát hiện ra các mẫu, các xu hướng, các quy luật ẩn và các mối liên hệ có ý nghĩa thống kê mà con người khó có thể nhận biết bằng các phương pháp thủ công. Về mặt kỹ thuật, khai phá dữ liệu là sự giao thoa của ba lĩnh vực khoa học chính:

- Thống kê: Cung cấp nền tảng toán học để phân tích định lượng, kiểm định giả thuyết và mô tả tính chất của dữ liệu.
- Học máy: Cung cấp các thuật toán để hệ thống có khả năng tự học hỏi, tối ưu hóa từ dữ liệu và đưa ra các dự đoán hoặc phân loại (như Logistic Regression, Random Forest, v.v.).
- Hệ quản trị cơ sở dữ liệu: Cung cấp các công cụ và kỹ thuật để lưu trữ, truy xuất, thao tác và quản lý dữ liệu lớn một cách hiệu quả trong kiến trúc Data Warehouse hoặc Data Lake.

b. Vai trò của khai phá dữ liệu trong y tế và chăm sóc sức khỏe

Trong lĩnh vực y tế, dữ liệu được sinh ra liên tục với khối lượng khổng lồ và độ phức tạp cao từ nhiều nguồn khác nhau: hồ sơ bệnh án điện tử (EHR), kết quả xét nghiệm lâm sàng, thiết bị theo dõi sức khỏe IoT, và đặc biệt là các hệ thống giám sát y tế cộng đồng quy mô lớn như bộ dữ liệu BRFSS (Behavioral Risk Factor Surveillance System) của CDC.

Nếu không có sự can thiệp của các kỹ thuật khai phá dữ liệu, những khối dữ liệu này chỉ là những con số và thông tin rời rạc, tồn tại trạng thái "nhiều dữ liệu nhưng khát tri thức". Khai phá dữ liệu giải quyết bài toán này thông qua việc:

- Phát hiện các yếu tố nguy cơ: Tìm ra mối tương quan ẩn giữa thói quen sinh hoạt (hút thuốc, mức độ vận động), chỉ số thể chất (BMI, huyết áp) với sự phát triển của bệnh lý. Ví dụ: Mô hình có thể phát hiện quy luật rằng một cá nhân trên 50 tuổi, có BMI vượt ngưỡng 30 và ít vận động sẽ có nguy cơ mắc tiểu đường cao gấp nhiều lần so với nhóm khác.
- Phân nhóm bệnh nhân: Phân chia tập cộng đồng thành các nhóm rủi ro khác nhau (Cao, Trung bình, Thấp) để có chiến lược can thiệp phù hợp.
- Hỗ trợ ra quyết định lâm sàng và dự phòng: Chuyển đổi kết quả phân tích thành các thông tin cảnh báo sớm có thể hành động được.

c, Ứng dụng cụ thể vào bài toán của đề tài

Đối với đề tài phân loại nguy cơ mắc bệnh tiểu đường, khai phá dữ liệu đóng vai trò là "bộ lọc" thông minh. Thay vì xử lý các chẩn đoán đắt đỏ và tốn thời gian tại bệnh viện, quy trình khai phá dữ liệu tận dụng bộ dữ liệu khảo sát cộng đồng để xây dựng mô hình dự đoán. Nhờ đó, hệ thống y tế có thể sàng lọc sớm trên diện rộng, tối ưu hóa chi phí y tế và giúp người dân thay đổi hành vi trước khi bệnh tiến triển sang các giai đoạn biến chứng nguy hiểm.

2.1.2. Bài toán phân loại

Phân loại là một trong những bài toán cốt lõi của Học có giám sát. Nhiệm vụ của hệ thống là tự động học các đặc trưng từ một tập dữ liệu đã được gán nhãn từ trước, sau đó xây dựng một mô hình có khả năng dự đoán nhãn cho các điểm dữ liệu mới.

a, Bản chất toán học và quá trình xấp xỉ hàm mục tiêu

Về mặt toán học định hình, bài toán phân loại được đặt trong một không gian đặc trưng d chiều. Giả sử ta có một tập dữ liệu huấn luyện $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, trong đó:

- $x_i = [x_{i1}, x_{i2}, \dots, x_{id}]^T \in R^d$ là vector đặc trưng đại diện cho bệnh nhân thứ i . Trong tập dữ liệu BRFSS, d là số lượng các biến số y tế (như độ tuổi, chỉ số BMI, huyết áp, thói quen hút thuốc,...).
- $y_i \in Y$ là nhãn phân lớp thực tế của bệnh nhân đó. Vì đề tài giải quyết bài toán phân loại nhị phân, không gian nhãn chỉ gồm hai giá trị: $Y = \{0, 1\}$.

- Lớp 0 (Negative Class): Biểu thị người khảo sát không mắc bệnh tiểu đường
- Lớp 1 (Positive Class): Biểu thị người khảo sát có nguy cơ hoặc đã mắc bệnh tiểu đường.

Quá trình học máy thực chất là quá trình đi tìm một tập tham số để tối ưu hóa một hàm mục tiêu $f(x, \theta)$. Mục đích là xấp xỉ hàm xác suất có điều kiện $P(Y = 1 | X, \theta)$ - tức là xác suất một người rơi vào Lớp 1 khi biết trước các chỉ số sức khỏe X của họ.

b, Ranh giới quyết định trong không gian n-chiều

Khi mô hình tiến hành phân loại, nó đang cố gắng phân chia không gian đặc trưng R^d thành các khu vực riêng biệt đại diện cho từng lớp. Đường hoặc mặt phẳng phân chia các khu vực này được gọi là Ranh giới quyết định.

Với mô hình baseline là Logistic Regression, ranh giới này là một siêu mặt phẳng (hyperplane) tuyến tính, định nghĩa bởi phương trình $\theta^T x = 0$. Nó phù hợp nếu dữ liệu có tính phân tách tuyến tính.

Với các mô hình nâng cao như Decision Tree hay Random Forest, ranh giới quyết định là tập hợp của nhiều mặt phẳng trực giao song song với các trục tọa độ, tạo ra các vùng phân phối phi tuyến tính, giúp nắm bắt được các mối quan hệ phức tạp (ví dụ: sự kết hợp đồng thời giữa "Tuổi > 50" và "BMI > 30" đẩy rủi ro lên rất cao).

c, Ngưỡng phân loại và ứng dụng trong y tế

Đầu ra thô của các mô hình phân loại nhị phân (đặc biệt là Logistic Regression hay Gradient Boosting) thường không phải là nhãn 0 hay 1 trực tiếp, mà là một giá trị dự đoán $p_{0,1}$ biểu thị xác suất mắc bệnh.

Để đưa ra quyết định cuối cùng, hệ thống cần áp dụng một ngưỡng phân loại (Threshold), với quy tắc:

- Dự đoán $\hat{y} = 1$ nếu $\hat{p} \geq \tau$
- Dự đoán $\hat{y} = 0$ nếu $\hat{p} < \tau$

Trong các bài toán thông thường, mặc định được đặt ở mức 0.5. Tuy nhiên, trong lĩnh vực y tế dự phòng, ngưỡng này thường được tinh chỉnh giảm xuống (ví dụ: 0.3 hoặc 0.4) nhằm chủ động cảnh báo sớm, chấp nhận việc dự đoán nhầm người khỏe thành

bệnh (tăng Độ chính xác dương tính giả) để đổi lấy việc không bỏ sót bất kỳ ai thực sự có rủi ro.

2.2. Các mô hình học máy sử dụng

2.2.1. Mô hình cơ sở: Hồi quy Logistic (*Logistic Regression*)

a, Cơ sở toán học

Mặc dù mang tên "Hồi quy", Logistic Regression là một thuật toán phân loại tuyến tính. Mô hình này không dự đoán trực tiếp nhãn phân lớp mà tính toán xác suất xảy ra của một sự kiện (trong trường hợp này là rủi ro mắc tiểu đường) dựa trên các biến độc lập.

Cho một vector đặc trưng $x = [x_1, x_2, \dots, x_d]^T$ chứa các thông tin y tế của bệnh nhân. Mô hình tính toán một tổ hợp tuyến tính các đặc trưng với tập trọng số $w = [w_1, w_2, \dots, w_d]^T$ và hệ số điều chỉnh (bias) b :

$$z = w^T x + b \quad (1)$$

Sau đó, giá trị z được đưa qua hàm kích hoạt Sigmoid để giới hạn đầu ra trong khoảng $(0, 1)$, đại diện cho xác suất $P(Y = 1 | x)$:

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} \quad (2)$$

Quá trình huấn luyện mô hình Logistic Regression là quá trình tìm kiếm bộ tham số tối ưu w, b bằng cách cực tiểu hóa hàm mất mát Binary Cross-Entropy:

$$L(w, b) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (3)$$

b, Vai trò và lý do lựa chọn Hồi quy Logistic làm cơ sở

Trong phương pháp luận nghiên cứu học máy, việc thiết lập một điểm chuẩn cơ sở là bước bắt buộc trước khi triển khai bất kỳ thuật toán phức tạp nào. Hồi quy Logistic được hệ thống lựa chọn để đảm nhận vị trí này dựa trên các vai trò và lý do cốt lõi sau:

– Về mặt vai trò:

+ Thiết lập thước đo chuẩn mực: Logistic Regression đóng vai trò là "chiếc mỏ neo" để đánh giá hiệu năng. Nó trả lời cho câu hỏi thiết yếu trong nghiên cứu:

"Liệu việc gia tăng độ phức tạp của thuật toán (sử dụng Random Forest hay Gradient Boosting) có thực sự mang lại sự cải thiện hiệu năng xứng đáng với chi phí tính toán bỏ ra hay không?". Nếu các mô hình nâng cao chỉ cho kết quả tương đương hoặc nhỉnh hơn không đáng kể so với baseline, hệ thống sẽ ưu tiên giữ lại mô hình tuyến tính để đảm bảo tính tinh gọn.

- + Kiểm chứng độ phức tạp của không gian đặc trưng: Kết quả đánh giá của Logistic Regression đóng vai trò như một bài test về tính tuyến tính của dữ liệu. Nếu mô hình đạt kết quả tốt, chứng tỏ các đặc trưng y tế có ranh giới phân chia rõ ràng. Ngược lại, nếu mô hình bị underfitting, điều này cung cấp minh chứng toán học vững chắc để biện luận cho sự cần thiết của các mô hình phi tuyến phía sau.
- Về mặt lý do lựa chọn:
 - + Tính minh bạch và khả năng giải thích lâm sàng: Đây là lý do quan trọng nhất trong lĩnh vực y tế. Khác với cấu trúc "hộp đen" của nhiều thuật toán khác, Logistic Regression cung cấp rõ ràng các trọng số w cho từng đặc trưng. Thông qua tỷ số chênh (Odds Ratio) được tính từ e^w , các chuyên gia y tế có thể định lượng chính xác được việc một bệnh nhân tăng 1 đơn vị BMI hoặc có hút thuốc sẽ làm tăng nguy cơ mắc tiểu đường lên bao nhiêu lần.
 - + Khả năng tinh chỉnh ngưỡng quyết định linh hoạt: Đầu ra của Logistic Regression là một giá trị xác suất liên tục $\hat{y} \in (0, 1)$ thay vì một nhãn cứng. Điều này cực kỳ phù hợp với bài toán y tế, nơi hệ thống có thể chủ động hạ ngưỡng phân loại (ví dụ: từ 0.5 xuống 0.3) để tăng Độ nhạy (Recall), thà bắt nhầm còn hơn bỏ sót bệnh nhân có rủi ro.
 - + Tối ưu chi phí và phù hợp với thiết kế hệ thống: Thuật toán hội tụ rất nhanh bằng các phương pháp tối ưu hóa như Gradient Descent, tiêu tốn ít RAM và tài nguyên CPU. Đặc tính này đáp ứng hoàn hảo với giới hạn của đề tài là không sử dụng hệ thống điện toán đám mây cấu hình cao, đồng thời phù hợp với cơ chế tái huấn luyện offline theo lô trên bộ dữ liệu quy mô lớn hàng trăm nghìn dòng như BRFS.

2.2.2. Các mô hình học máy nâng cao

Để khắc phục giới hạn của mô hình tuyến tính trong việc nắm bắt các mối liên hệ phức tạp chéo giữa các đặc trưng y tế, hệ thống triển khai thêm bốn thuật toán nâng cao:

a, Decision Tree

Cây quyết định là mô hình phân loại phi tham số, hoạt động bằng cách chia nhỏ không gian dữ liệu liên tục thành các vùng hình chữ nhật thông qua các quy tắc quyết định (nếu - thì).

- Cơ chế hoạt động: Tại mỗi nút (node), thuật toán chọn ra một đặc trưng và một ngưỡng phân chia sao cho dữ liệu ở các nút con đạt độ thuần nhất cao nhất. Độ thuần nhất thường được đo bằng Entropy hoặc Gini Impurity. Công thức tính Gini cho một nút có C lớp với xác suất p_i là:

$$Gini = 1 - \sum_{i=1}^C p_i^2 \quad (4)$$

- Ưu điểm trong bài toán: Mô hình xử lý tốt dữ liệu khuyết thiếu, không yêu cầu chuẩn hóa dữ liệu đầu vào. Tuy nhiên, một cây đơn lẻ rất dễ bị quá khớp với tập dữ liệu huấn luyện.

b, Random Forest

Để giải quyết nhược điểm overfitting của Cây quyết định, Random Forest ra đời dựa trên kỹ thuật học tập hợp, cụ thể là phương pháp Bagging.

- Cơ chế hoạt động: Mô hình tạo ra M cây quyết định khác nhau. Mỗi cây được huấn luyện trên một tập dữ liệu con lấy mẫu ngẫu nhiên có hoàn lại từ tập gốc. Hơn nữa, tại mỗi bước phân nhánh, mô hình chỉ xem xét một tập con ngẫu nhiên các đặc trưng. Kết quả phân loại cuối cùng được quyết định bằng cơ chế biểu quyết đa số từ tất cả các cây.
- Ưu điểm trong bài toán: Có khả năng tổng quát hóa rất cao, chống nhiễu tốt đối với các sai số đo lường trong dữ liệu khảo sát và tự động đánh giá được tầm quan trọng của các đặc trưng.

c, Gradient Boosting

Tương tự như Random Forest, Gradient Boosting là một kỹ thuật học tập hợp, nhưng thay vì sử dụng phương pháp Bagging, nó sử dụng chiến lược Boosting.

- Cơ chế hoạt động: Mô hình xây dựng một chuỗi các mô hình học yếu- thường là các cây quyết định nông. Đặc điểm cốt lõi là cây quyết định ở bước thứ m sẽ tập trung vào việc dự đoán và bù đắp những sai số mà các cây từ 1 đến $m - 1$ trước đó đã dự đoán sai.
- Về mặt toán học, thuật toán xấp xỉ hàm mục tiêu Fx bằng cách tối ưu hóa một hàm mất mát có thể đạo hàm $L=y, Fx$. Tại mỗi vòng lặp m , thuật toán tính toán pseudo-residuals (đạo hàm bậc nhất của hàm mất mát):

$$r_{im} = \left[\frac{\delta L(y_i, F(x_i))}{\delta F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (5)$$

d, K-Nearest Neighbors (KNN)

K-Nearest Neighbors là một thuật toán thuộc nhóm học dựa trên thực thể và học lười biếng. Thay vì xây dựng một hàm xấp xỉ tổng quát hóa ngay trong pha huấn luyện (như Logistic Regression hay Decision Tree), KNN lưu trữ toàn bộ tập dữ liệu và chỉ thực hiện tính toán khi có yêu cầu dự đoán.

- Cơ chế hoạt động: Để phân loại một bệnh nhân mới có vector đặc trưng x , thuật toán sẽ đo lường khoảng cách từ x đến tất cả các điểm dữ liệu trong tập huấn luyện. Khoảng cách thường được tính bằng chuẩn khoảng cách Euclidean:

$$d(x, x') = \sqrt{\sum_{j=1}^d (x_j - x'_j)^2} \quad (6)$$

- Sau khi xác định được K điểm dữ liệu (bệnh nhân) có khoảng cách gần nhất với x , mô hình sẽ gán nhãn cho bệnh nhân mới dựa trên cơ chế biểu quyết đa số (Majority Voting) của K láng giềng này.
- Đặc thù khi áp dụng: Điểm mạnh của KNN là tính phi tham số, không đưa ra bất kỳ giả định nào về phân phối của dữ liệu gốc. Tuy nhiên, khi áp dụng vào bài toán phân loại tiểu đường, KNN đòi hỏi kỹ thuật tiền xử lý dữ liệu cực kỳ khắt khe (phải chuẩn hóa Min-Max hoặc Z-score cho các biến như BMI, Tuổi) để tránh tình trạng các đặc trưng có thang đo lớn lấn át đặc trưng có thang đo nhỏ. Đồng thời, mô hình

này yêu cầu chi phí tính toán lớn ở pha suy luận do phải duyệt qua toàn bộ dữ liệu mẫu, điều này cần được cân nhắc kỹ trong kiến trúc hệ thống.

2.3. Phương pháp đánh giá

Để đảm bảo các mô hình phân loại hoạt động hiệu quả và khách quan trên tập dữ liệu y tế BRFSS, hệ thống áp dụng chiến lược phân chia dữ liệu, huấn luyện chéo và sử dụng tập hợp các chỉ số đánh giá tập trung vào việc giảm thiểu rủi ro chẩn đoán sót bệnh nhân.

2.3.1. Chiến lược phân chia dữ liệu và huấn luyện chéo

Để đảm bảo quá trình đánh giá mô hình phản ánh đúng khả năng tổng quát hóa trên dữ liệu thực tế, toàn bộ tập dữ liệu được chia thành hai phần: tập huấn luyện chiếm 80% và tập kiểm thử chiếm 20%. Quá trình phân chia được thực hiện theo cơ chế phân tầng (stratified split), nhằm duy trì tỷ lệ giữa hai lớp dữ liệu — mắc bệnh và không mắc bệnh — trong cả tập huấn luyện và tập kiểm thử tương đồng với phân bố của dữ liệu ban đầu. Cách tiếp cận này giúp hạn chế hiện tượng lệch phân phối dữ liệu giữa các tập, từ đó nâng cao tính khách quan của quá trình đánh giá mô hình.

Bên cạnh đó, để lựa chọn bộ siêu tham số tối ưu cho từng thuật toán đồng thời giảm nguy cơ quá khớp (overfitting), hệ thống áp dụng phương pháp GridSearchCV kết hợp với kỹ thuật huấn luyện chéo K-Fold Cross Validation với số nếp gấp $K = 3$. Trong quá trình này, tập huấn luyện được chia thành ba phần, luân phiên sử dụng cho mục đích huấn luyện và kiểm định. Cơ chế đánh giá lặp lại trên nhiều tập con dữ liệu giúp mô hình đạt được khả năng tổng quát hóa tốt hơn và đảm bảo kết quả lựa chọn tham số mang tính ổn định, đáng tin cậy hơn so với việc đánh giá trên một lần chia dữ liệu duy nhất.

2.3.2. Các chỉ số đo lường hiệu năng

Quá trình đánh giá hiệu suất của mô hình được dựa trên Ma trận nhầm lẫn sinh ra từ tập kiểm thử. Để xây dựng các chỉ số đánh giá, các biến số thành phần được định nghĩa như sau:

- TP (True Positive - Dương tính thật): Bệnh nhân thực sự mắc tiểu đường và mô hình dự đoán đúng.

- TN (True Negative - Âm tính thật): Người khỏe mạnh và mô hình dự đoán đúng không mắc bệnh.
- FP (False Positive - Dương tính giả): Người khỏe mạnh nhưng mô hình báo động nhầm là mắc bệnh.
- FN (False Negative - Âm tính giả): Bệnh nhân mắc tiểu đường nhưng mô hình chẩn đoán sai là khỏe mạnh.

Dựa trên các cấu phần này, các chỉ số được hệ thống ghi nhận và tính toán bao gồm:

a, Độ chính xác (Accuracy)

Accuracy là chỉ số đo tỷ lệ dự đoán đúng của mô hình trên toàn bộ tập dữ liệu kiểm thử.

Accuracy được tính theo công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (7)$$

Mặc dù Accuracy là chỉ số phổ biến và dễ hiểu, nhưng trong các bài toán dữ liệu mất cân bằng, chỉ số này có thể dẫn đến những đánh giá sai lệch về hiệu năng thực sự của mô hình. Ví dụ, nếu tập dữ liệu bao gồm: 90% người khỏe mạnh, và chỉ 10% người mắc tiểu đường, thì một mô hình luôn dự đoán tất cả đối tượng đều “không mắc bệnh” vẫn có thể đạt Accuracy lên tới 90%. Tuy nhiên, mô hình này hoàn toàn không có khả năng phát hiện bệnh nhân thực sự và do đó không mang giá trị ứng dụng trong thực tế y tế. Vì lý do đó, trong bài toán dự đoán bệnh tiểu đường, Accuracy không nên được sử dụng như tiêu chí đánh giá duy nhất. Thay vào đó, cần kết hợp với các chỉ số khác nhằm đánh giá toàn diện hơn khả năng phát hiện bệnh của mô hình.

b, Độ chính xác của dự đoán tích cực (Precision)

Precision là chỉ số đo tỷ lệ các trường hợp thực sự mắc bệnh trong tổng số các trường hợp được mô hình dự đoán là mắc bệnh. Nói cách khác, Precision phản ánh mức độ tin cậy của các cảnh báo dương tính mà mô hình đưa ra.

Precision được tính theo công thức:

$$Precision = \frac{TP}{TP + FP} \quad (8)$$

Precision có ý nghĩa đặc biệt quan trọng trong các hệ thống hỗ trợ chẩn đoán y tế, vì chỉ số này ảnh hưởng trực tiếp đến chi phí và hiệu quả của quá trình kiểm chứng lâm sàng. Khi Precision ở mức thấp, tỷ lệ dương tính giả sẽ tăng cao. Điều này đồng nghĩa với việc hệ thống thường xuyên nhận diện nhầm những người khỏe mạnh thành đối tượng có nguy cơ mắc bệnh. Các dự đoán sai lệch như vậy không chỉ gây hoang mang tâm lý cho người được kiểm tra mà còn làm gia tăng đáng kể chi phí xét nghiệm, thời gian chẩn đoán và áp lực cho cơ sở y tế do phải thực hiện thêm nhiều kiểm tra chuyên sâu không cần thiết. Ngược lại, Precision cao cho thấy phần lớn các cảnh báo dương tính của mô hình là chính xác, từ đó giúp nâng cao độ tin cậy và hiệu quả ứng dụng của hệ thống trong thực tế.

c, Tỷ lệ dự đoán đúng tích cực (Recall)

Recall là chỉ số đo tỷ lệ số ca mắc bệnh được mô hình phát hiện đúng trên tổng số các trường hợp thực sự mắc bệnh. Chỉ số này phản ánh khả năng “tầm soát” của mô hình, tức mức độ phát hiện đầy đủ các đối tượng mang bệnh mà không bỏ sót.

Recall được tính theo công thức:

$$Recall = \frac{TP}{TP + FN} \quad (9)$$

Trong lĩnh vực y tế, Recall được xem là một trong những chỉ số quan trọng nhất vì nó phản ánh trực tiếp mức độ an toàn của hệ thống đối với người bệnh.

Khi Recall ở mức thấp, tỷ lệ âm tính giả sẽ tăng cao. Điều này đồng nghĩa với việc hệ thống bỏ sót nhiều bệnh nhân thực sự mắc bệnh và kết luận sai rằng họ hoàn toàn khỏe mạnh. Hậu quả của những dự đoán sai lệch này có thể rất nghiêm trọng, bởi người bệnh sẽ mất cơ hội được phát hiện và can thiệp y tế kịp thời. Đối với bệnh tiểu đường, việc chẩn đoán muộn có thể dẫn đến nhiều biến chứng nguy hiểm. Vì vậy, trong bài toán y tế như dự đoán nguy cơ mắc bệnh tiểu đường, Recall thường được ưu tiên tối ưu hơn so với nhiều chỉ số khác nhằm giảm thiểu nguy cơ bỏ sót bệnh nhân thực sự mắc bệnh.

d, F1-score

F1-score là chỉ số đánh giá tổng hợp giữa Precision và Recall, được sử dụng nhằm phản ánh sự cân bằng giữa khả năng phát hiện đúng bệnh nhân và độ tin cậy của các dự đoán dương tính.

Khác với Accuracy chỉ đánh giá tỷ lệ dự đoán đúng tổng thể, F1-score đặc biệt hữu ích trong các bài toán phân loại mất cân bằng, nơi cần đồng thời quan tâm đến cả việc giảm bỏ sót bệnh nhân và hạn chế cảnh báo nhầm.

F1-score được tính theo công thức:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (10)$$

Do là trung bình điều hòa giữa Precision và Recall, F1-score sẽ chỉ đạt giá trị cao khi cả hai chỉ số này đều cao. Nếu một trong hai chỉ số thấp, F1-score cũng sẽ giảm đáng kể.

Trong bài toán dự đoán bệnh tiểu đường, F1-score có ý nghĩa quan trọng vì hệ thống không chỉ cần phát hiện được nhiều bệnh nhân thực sự mắc bệnh mà còn phải đảm bảo các cảnh báo đưa ra có độ tin cậy hợp lý. Nếu mô hình chỉ tối ưu Recall mà bỏ qua Precision, hệ thống có thể phát hiện gần như toàn bộ bệnh nhân nhưng đồng thời tạo ra quá nhiều cảnh báo sai, gây lãng phí nguồn lực y tế. Ngược lại, nếu chỉ tối ưu Precision mà Recall thấp, mô hình có thể bỏ sót nhiều bệnh nhân thực sự mắc bệnh, làm giảm hiệu quả tầm soát.

Do đó, F1-score đóng vai trò là chỉ số đánh giá cân bằng giữa khả năng phát hiện bệnh và mức độ chính xác của các cảnh báo, giúp phản ánh toàn diện hơn hiệu năng thực tế của mô hình trong môi trường y tế.

e, Chỉ số diện tích đường cong ROC (AUC-ROC)

AUC-ROC (Area Under the Receiver Operating Characteristic Curve) đo lường khả năng phân tách giữa lớp dương tính và lớp âm tính của mô hình tại nhiều ngưỡng phân loại khác nhau.

Khác với Accuracy hay Precision chỉ đánh giá mô hình tại một ngưỡng phân loại cố định, AUC-ROC phản ánh hiệu năng tổng quát của mô hình trên nhiều ngưỡng phân loại khác nhau.

Đường cong ROC (Receiver Operating Characteristic Curve) được xây dựng bằng cách biểu diễn True Positive Rate (TPR) trên trục tung và False Positive Rate (FPR) trên trục hoành. Công thức diện tích được tính bằng tích phân:

$$AUC = \int_0^1 TPR d(FPR) \quad (11)$$

Trong đó TPR chính là Recall.

Giá trị AUC càng cao cho thấy mô hình càng có khả năng phân tách tốt giữa hai lớp dữ liệu.

Cụ thể:

- AUC gần 1 cho thấy mô hình có khả năng phân loại rất tốt,
- AUC khoảng 0.5 cho thấy mô hình gần như không có khả năng học được quy luật dữ liệu và kết quả dự đoán chỉ tương đương với đoán ngẫu nhiên.

Trong bài toán dự đoán bệnh tiểu đường, AUC-ROC đóng vai trò quan trọng vì nó phản ánh mức độ ổn định và độ tin cậy tổng quát của mô hình, không phụ thuộc vào một ngưỡng quyết định cụ thể. Một mô hình có giá trị AUC cao, ví dụ khoảng 0.9 trở lên, cho thấy thuật toán đã học được các đặc trưng bệnh lý cốt lõi và có khả năng phân biệt hiệu quả giữa người mắc bệnh và người không mắc bệnh. Ngược lại, nếu AUC tiệm cận 0.5, điều đó cho thấy mô hình không thực sự khai thác được thông tin hữu ích từ dữ liệu và gần như không có giá trị ứng dụng thực tiễn.

Trong quá trình huấn luyện và lựa chọn mô hình, Recall được sử dụng làm tiêu chí tối ưu chính trong GridSearchCV, đồng thời là cơ sở quan trọng để so sánh hiệu năng giữa các thuật toán học máy. Việc ưu tiên tối đa hóa Recall đồng nghĩa với việc hệ thống tập trung nâng cao khả năng phát hiện các trường hợp có nguy cơ mắc bệnh, ngay cả khi phải chấp nhận sự suy giảm nhất định về Accuracy hoặc Precision. Lý do của lựa chọn này xuất phát từ đặc thù của bài toán y tế dự phòng. Trong thực tế, hậu quả của việc không phát hiện được một bệnh nhân tiểu đường tiềm ẩn thường nghiêm trọng hơn nhiều so với việc cảnh báo nhầm một người khỏe mạnh. Vì vậy, hệ thống được thiết kế theo hướng ưu tiên khả năng sàng lọc và phát hiện sớm nhằm giảm thiểu tối đa nguy cơ bỏ sót các trường hợp cần can thiệp y tế.

2.4. Cơ chế cập nhật và tái huấn luyện mô hình định kỳ

Hệ thống được thiết kế theo hướng pipeline tự động trên môi trường offline. Để giải quyết bài toán suy giảm hiệu năng do sự sai lệch dữ liệu theo thời gian, quy trình

tái huấn luyện được quản lý nghiêm ngặt qua các bước lưu vết và sinh siêu dữ liệu (metadata).

2.4.1. Khởi tạo Hồ sơ dữ liệu

Trước khi đưa dữ liệu vào huấn luyện, hệ thống tự động quét và xây dựng một hồ sơ dữ liệu chi tiết. Quá trình này trích xuất siêu dữ liệu của từng đặc trưng đầu vào, bao gồm:

- Kiểu dữ liệu và cờ xác nhận dữ liệu dạng số.
- Số lượng và tỷ lệ giá trị khuyết thiếu.
- Số lượng giá trị duy nhất.
- Các chỉ số thống kê cơ bản: Giá trị nhỏ nhất, lớn nhất và trung bình.

Vai trò: Hồ sơ này đóng vai trò như một mốc tham chiếu. Khi có lô dữ liệu khảo sát mới, hệ thống sẽ đối chiếu với hồ sơ này để phát hiện các thay đổi bất thường về cấu trúc hoặc phân phối thống kê trước khi kích hoạt huấn luyện.

2.4.2. Pipeline Tái huấn luyện theo lô

Hệ thống được thiết kế và vận hành theo chiến lược tái huấn luyện chủ động (On-demand Retraining), áp dụng triệt để nguyên lý có sự can thiệp của con người (Human-in-the-loop). Thay vì phụ thuộc vào các chu kỳ thời gian cố định hay các ngưỡng kích hoạt tự động dựa trên khối lượng dữ liệu mới, vòng đời tái huấn luyện của hệ thống hoàn toàn do quản trị viên y tế quyết định. Sự vắng mặt của các bộ định thời hay cơ chế giám sát ngầm trong mã nguồn khẳng định rằng hệ thống không tự động cập nhật mô hình. Mọi tiến trình chỉ được khởi chạy thông qua các thao tác trực tiếp trên giao diện quản trị Streamlit.

Cụ thể, quy trình này được đặt tại phân hệ "Upload & Tái huấn luyện". Khi cơ sở y tế thu thập được một lượng dữ liệu bệnh nhân mới đủ lớn và đã qua sơ chế, quản trị viên sẽ tiến hành tải các tệp định dạng CSV này lên hệ thống. Sau khi thao tác kích hoạt được xác nhận thông qua nút lệnh khởi chạy, hệ thống mới bắt đầu gọi đến các hàm xử lý lỗi. Từ thời điểm này, một luồng tự động hóa khép kín mới được thực thi, bao gồm các bước: gộp tập dữ liệu, đối chiếu cấu trúc, đo lường sự suy thoái dữ liệu và cuối cùng là tổ chức huấn luyện, đánh giá theo cơ chế Champion - Challenger.

Quyết định thiết kế theo hướng thủ công này hoàn toàn có chủ đích và đặc biệt phù hợp với đặc thù khắt khe của lĩnh vực y tế. Dữ liệu bệnh lý đòi hỏi tính chính xác tuyệt đối và phải trải qua quá trình kiểm chứng nghiêm ngặt. Việc trao quyền quyết định thời điểm tái huấn luyện cho chuyên gia giúp đảm bảo tính toàn vẹn của dữ liệu đầu vào. Cách tiếp cận này triệt tiêu hoàn toàn rủi ro mô hình bị học lệch hoặc suy giảm hiệu suất do hệ thống tự động nạp phải các lô dữ liệu rác, dữ liệu chứa nhiễu hoặc sai sót trong quá trình nhập liệu từ các cơ sở y tế. Bằng cách này, hệ thống vừa duy trì được sự linh hoạt trong việc cập nhật tri thức mới, vừa đảm bảo được tính ổn định và độ tin cậy tối đa cho các kết luận chẩn đoán.

Bên cạnh cơ chế tái huấn luyện chủ động dựa trên quyết định của con người, hệ thống còn được tích hợp song song một luồng quy trình tự động hóa theo định kỳ. Cụ thể, một chu kỳ tái huấn luyện tự động được thiết lập để kích hoạt ngầm vào mỗi dịp cuối tuần. Thông qua cấu hình của các công cụ lập lịch tác vụ hệ thống, máy chủ sẽ tự động quét kho lưu trữ dữ liệu đầu vào. Nếu phát hiện có các lô dữ liệu bệnh lý mới được tích lũy trong suốt tuần qua, tập lệnh tái huấn luyện sẽ tự động thực thi toàn bộ chu trình từ đối chiếu cấu trúc, đo lường trôi dạt dữ liệu cho đến huấn luyện mô hình mà không cần thao tác kích hoạt trực tiếp từ quản trị viên.

Việc triển khai kiến trúc lai kết hợp giữa thủ công và tự động này mang lại sự cân bằng hoàn hảo cho hệ thống. Một mặt, nó vẫn duy trì được khả năng cập nhật khẩn cấp và kiểm soát dữ liệu thủ công thông qua giao diện khi cần thiết. Mặt khác, luồng chạy ngầm tự động vào cuối tuần đóng vai trò như một chốt chặn an toàn, giúp thuật toán tránh khỏi hiện tượng suy thoái tri thức trong trường hợp quản trị viên lơ là việc cập nhật. Hơn thế nữa, chiến lược dịch chuyển các tác vụ huấn luyện nặng nề về thời điểm cuối tuần cũng là một giải pháp tối ưu hóa tài nguyên máy chủ một cách triệt để, tận dụng tối đa khung thời gian thấp điểm để thực thi tính toán mà không làm gián đoạn hay ảnh hưởng đến tốc độ phản hồi của hệ thống chẩn đoán trực tuyến.

2.4.3. Đánh giá tự động và Lưu trữ mô hình

Sau khi kết thúc huấn luyện, mô hình được cập nhật theo cơ chế tự động đánh giá:

- Champion-Challenger: Hệ thống trích xuất chỉ số `test_recall` của từng mô hình. Thuật toán có chỉ số Recall cao nhất sẽ được tự động chỉ định là Mô hình tốt nhất (Best Model).

- Xuất báo cáo: Hệ thống sinh tệp kết quả tổng hợp `model_results.csv` để xếp hạng các mô hình, đồng thời xuất chi tiết Ma trận nhầm lẫn và Classification Report vào tệp `best_model_report.txt`.
- Lưu trữ và Truy xuất: Bằng thư viện `joblib`, hệ thống đóng gói toàn bộ từ điển các mô hình (`all_models.pkl`) và tách riêng mô hình xuất sắc nhất (`best_model.pkl`).
- Lưu vết Metadata: Một tệp `run_metadata.json` được tạo ra để ghi nhận số dòng, số cột, siêu tham số tối ưu, và đường dẫn tệp dữ liệu. Cơ chế này đảm bảo toàn bộ quy trình tái huấn luyện có tính kế thừa, dễ dàng truy vết và cho phép triển khai mô hình vào pha suy luận ngay lập tức.

CHƯƠNG 3. MÔ TẢ VÀ PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

3.1. Giới thiệu bộ dữ liệu

Bộ dữ liệu sử dụng trong nghiên cứu được lấy từ cuộc khảo sát Behavioral Risk Factor Surveillance System (BRFSS) năm 2015 do Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh Hoa Kỳ (CDC) thực hiện. Đây là cuộc khảo sát sức khỏe điện thoại thường niên, thu thập thông tin về các yếu tố nguy cơ sức khỏe của hàng trăm nghìn công dân Mỹ mỗi năm. Phiên bản được sử dụng trong đề tài là tệp `diabetes_binary_5050split_health_indicators_BRFSS2015.csv`, được công bố trên nền tảng Kaggle.

Bộ dữ liệu bao gồm 70.692 mẫu quan sát và 22 biến đặc trưng, trong đó có 1 biến mục tiêu (`Diabetes_binary`) và 21 biến đầu vào phản ánh các khía cạnh sức khỏe, lối sống và nhân khẩu học của đối tượng khảo sát. Đặc điểm nổi bật của phiên bản này là tỉ lệ lớp được cân bằng hoàn hảo ở mức 50/50 thông qua kỹ thuật undersampling ngẫu nhiên từ bộ dữ liệu gốc — vốn có tỉ lệ dương tính chỉ khoảng 14%.

3.1.1. Phân loại các biến đặc trưng

Toàn bộ 22 biến trong tập dữ liệu được phân loại thành sáu nhóm chức năng dựa trên bản chất thông tin mà chúng biểu diễn. Cách phân loại này không chỉ giúp tổ chức phân tích EDA một cách có hệ thống, mà còn cung cấp cơ sở để lý giải ý nghĩa lâm sàng và xã hội của từng đặc trưng trong bối cảnh bài toán dự đoán nguy cơ tiểu đường.

Bảng 3.1. Phân loại 22 biến đặc trưng theo nhóm chức năng.

Nhóm	Biến	Mô tả	Loại
Biến mục tiêu	Diabetes_binary	0 = Không tiểu đường 1 = Tiểu đường/ Tiền tiểu đường	Nhị phân
Chỉ số sức khỏe	BMI	Chỉ số khối cơ thể (12 – 98)	Liên tục
	HighBP	Huyết áp cao đã được chẩn đoán	Nhị phân
	HighChol	Cholesterol cao đã được chẩn đoán	Nhị phân

	CholCheck	Đã kiểm tra cholesterol trong 5 năm qua	Nhị phân
Lối sống	Smoker	Đã hút ít nhất 100 điếu thuốc trong đời	Nhị phân
	PhysActivity	Có hoạt động thể chất trong 30 ngày qua	Nhị phân
	Fruits	Ăn trái cây ít nhất 1 lần/ngày	Nhị phân
	Veggies	Ăn rau xanh ít nhất 1 lần/ngày	Nhị phân
	HvyAlcoholConsump	Uống rượu nặng (>14 ly/tuần với Nam, >7 ly/tuần với Nữ)	Nhị phân
Nhân khẩu học	Age	Nhóm tuổi (1=18–24 đến 13= $\geq$ 80 tuổi)	Thứ bậc
	Sex	Giới tính (0=Nữ, 1=Nam)	Nhị phân
	Education	Trình độ học vấn (thang 1–6)	Thứ bậc
	Income	Mức thu nhập (thang 1–8, từ < 10K đến > 75K)	Nhị phân
Bệnh lý	Stroke	Tiền sử đột quỵ	Nhị phân
	HeartDiseaseorAttack	Bệnh tim mạch hoặc nhồi máu cơ tim	Nhị phân
	DiffWalk	Khó khăn khi đi bộ hoặc leo cầu thang	
	GenHlth	Tự đánh giá sức khỏe tổng quát (1=Xuất sắc $\rightarrow$ 5=Kém)	Thứ bậc

	MentHlth	Số ngày sức khỏe tâm thần kém trong 30 ngày qua	Liên tục
	PhysHlth	Số ngày sức khỏe thể chất kém trong 30 ngày qua	Liên tục
Tiếp cận y tế	AnyHealthcare	Có bảo hiểm y tế	Nhị phân
	NoDocbcCost	Không đến gặp bác sĩ vì chi phí	Nhị phân

3.2. Phân tích phân phối (EDA)

3.2.1. Thống kê mô tả

Bảng 3.2 tổng hợp các chỉ số thống kê cơ bản cho các biến liên tục và thứ bậc trong tập dữ liệu, bao gồm giá trị trung bình (μ), trung vị, độ lệch chuẩn (σ), giá trị cực biên (min/max), các phân vị tứ phân vị (Q1, Q3) và hệ số độ lệch phân phối (Skewness). Đây là nền tảng để đánh giá xu hướng tập trung, mức độ phân tán và phát hiện các giá trị phi thực tế trước khi tiến hành tiền xử lý.

Bảng 3.2. Thống kê mô tả các biến số trong tập dữ liệu.


Biến	Trung bình (μ)	Trung vị	Độ lệch chuẩn (σ)	Min	Max	Q1	Q3	Skewnes
BMI	29.86	29.00	7.11	12	98	25	33	1.72 (phải)
MentHlth	3.75	0.00	8.16	0	30	0	2	2.39 (phải)
PhysHlth	5.81	0.00	10.06	0	30	0	6	1.66 (phải)
GenHlth	2.84	3.00	1.11	1	5	2	4	0.17 (cân)

Age	8.58	9.00	2.85	1	13	7	11	-0.55 (trái)
Education	4.92	5.00	1.03	1	6	4	6	-0.68 (trái)
Income	5.70	6.00	2.18	1	8	4	8	-0.65 (trái)

Phân tích bảng thống kê cho thấy một số đặc điểm đáng chú ý. Chỉ số BMI có giá trị trung bình 29.86 — nằm ở ngưỡng thừa cân theo phân loại WHO (25–29.9) — với độ lệch chuẩn $\sigma = 7.11$, phản ánh mức độ phân tán khá rộng trong tập mẫu. Giá trị tối đa của BMI đạt 98, là giá trị bất thường cần kiểm tra kỹ hơn ở bước phân tích ngoại lai. Hai biến MentHlth và PhysHlth đều có trung vị bằng 0 nhưng trung bình lần lượt là 3.75 và 5.81, phản ánh phân phối lệch phải điển hình của dữ liệu y tế dạng "zero-inflated" — đại đa số người không có ngày sức khỏe kém, nhưng một nhóm nhỏ có nhiều ngày xấu kéo dài làm trung bình bị kéo lên. Biến Age có trung vị = 9, tương ứng nhóm tuổi 55–59, cho thấy mẫu khảo sát thiên về đối tượng trung niên và cao tuổi, phù hợp với nhóm có nguy cơ tiểu đường cao nhất trong thực tế lâm sàng.

3.2.2. Phân tích phân phối biến mục tiêu và cân bằng lớp

Phân phối của biến mục tiêu Diabetes_binary là bước phân tích quan trọng đầu tiên vì nó quyết định trực tiếp đến chiến lược huấn luyện mô hình, lựa chọn metric đánh giá và sự cần thiết của các kỹ thuật xử lý mất cân bằng dữ liệu.




Hình 3.1. Phân bố biến mục tiêu Diabetes_binary.

Nhìn vào hình 3.1, phân tích phân bố biến mục tiêu cho thấy tập dữ liệu có tỉ lệ cân bằng lớp hoàn hảo: lớp 0 (không tiểu đường) có đúng 35.346 mẫu và lớp 1 (có tiểu đường hoặc tiền tiểu đường) cũng có 35.346 mẫu, chiếm tỉ lệ 50% mỗi bên. Sự cân bằng này là kết quả của quá trình undersampling ngẫu nhiên từ bộ dữ liệu BRFSS 2015 gốc vốn mất cân bằng (khoảng 14% dương tính). Điều này mang lại hai hệ quả quan trọng cho quá trình xây dựng mô hình: thứ nhất, không cần áp dụng các kỹ thuật cân bằng dữ liệu như SMOTE hay class weighting ở bước tiền xử lý; thứ hai, Accuracy có thể được sử dụng như một metric đánh giá hợp lệ song song cùng F1-score và ROC-AUC.

3.2.3. Trực quan hóa dữ liệu

Chỉ số BMI (Body Mass Index) là một trong những yếu tố sinh học quan trọng nhất được ghi nhận trong nghiên cứu dịch tễ học về tiểu đường type 2. Giá trị BMI phản ánh mức độ thừa cân và béo phì của cá nhân, đây là yếu tố nguy cơ có cơ chế sinh lý rõ ràng thông qua đề kháng insulin.




Hình 3.2. Histogram và Boxplot so sánh BMI giữa nhóm có và không có tiểu đường.

Kết quả phân tích từ hình 3.2 cho thấy sự phân tách rõ rệt giữa hai nhóm. BMI trung bình của nhóm có tiểu đường đạt 31.94 — nằm trong ngưỡng béo phì độ I theo phân loại WHO — cao hơn đáng kể so với nhóm không tiểu đường có BMI trung bình 27.77 (ngưỡng thừa cân). Mức chênh lệch khoảng 4.2 điểm BMI giữa hai nhóm là có ý nghĩa thống kê và lâm sàng. Biểu đồ Boxplot xác nhận rằng trung vị, Q1 và Q3 của nhóm có tiểu đường đều cao hơn đáng kể so với nhóm không tiểu đường, với phần đuôi trên mở rộng hơn ở nhóm bệnh. Cả hai nhóm đều thể hiện phân phối lệch phải (skewness = 1.72 chung cả tập), với phần đuôi kéo dài về phía các giá trị BMI cao. Hệ số tương

quan Pearson giữa BMI và biến mục tiêu đạt $r = +0.293$, xếp thứ 3 trong số tất cả các đặc trưng, khẳng định vai trò dự báo quan trọng của biến này.

3.2.4. Phân tích các biến nhị phân theo nhóm tiểu đường

Tập dữ liệu chứa 14 biến nhị phân phản ánh sự hiện diện hay vắng mặt của các yếu tố sức khỏe, lối sống và bệnh lý. Phân tích so sánh tỉ lệ xuất hiện của từng biến (giá trị = 1) giữa hai nhóm tiểu đường và không tiểu đường giúp xác định những yếu tố có khả năng phân biệt nhóm cao nhất.



Hình 3.3. Tỉ lệ (%) các đặc trưng nhị phân theo nhóm tiểu đường.


Bảng 3.3. So sánh tỉ lệ xuất hiện biến nhị phân giữa hai nhóm.

Biến	Không ĐTĐ (%)	Có ĐTĐ (%)	Chênh lệch	Nhận xét
HighBP	37.4%	75.3%	+37.9%	Yếu tố nguy cơ lớn nhất trong tập dữ liệu
HighChol	38.1%	67.0%	+28.9%	Liên quan chặt đến rối loạn chuyển hóa
DiffWalk	13.4%	37.1%	+23.7%	Biến chứng thần kinh do tiểu đường
HeartDiseaseorAttack	7.3%	22.3%	+15.0%	Bệnh đi kèm – comorbidity phổ biến

Stroke	3.2%	9.2%	+6.0%	Liên quan đến biến chứng mạch máu
PhysActivity	77.6%	63.1%	−14.5%	Người ĐTĐ vận động ít hơn đáng kể
HvyAlcoholConsump	6.2%	2.4%	−3.8%	Người ĐTĐ đã hạn chế rượu sau chẩn đoán

3.2.5. Phân tích các biến thứ bậc

Bốn biến thứ bậc trong tập dữ liệu — GenHlth, Age, Income và Education — đóng vai trò quan trọng trong việc phản ánh bức tranh tổng thể về tình trạng sức khỏe, nhân khẩu học và kinh tế xã hội của đối tượng khảo sát.




Hình 3.4. Phân phối các biến thứ bậc theo nhóm tiểu đường.

Kết quả phân tích từ hình 3.4 cho thấy một số xu hướng rõ nét. Đối với biến GenHlth (sức khỏe tổng quát tự đánh giá), nhóm có tiểu đường tập trung đáng kể hơn ở mức 4 (Bình thường) và mức 5 (Kém), trong khi nhóm không tiểu đường phân bố nhiều hơn ở mức 1 và 2 (Xuất sắc/Rất tốt). GenHlth đạt hệ số tương quan cao nhất với biến mục tiêu ($r = +0.408$), khẳng định đây là đặc trưng dự báo mạnh nhất. Đối với biến Age, tỉ lệ mắc tiểu đường tăng rõ rệt theo độ tuổi, đặc biệt từ nhóm 7 (45–49 tuổi) trở lên, với

nhóm cao tuổi (≥ 65 tuổi, nhóm 11–13) có tỉ lệ tiểu đường áp đảo — phù hợp với sinh lý học về giảm độ nhạy insulin theo tuổi. Đối với biến Income, người có thu nhập thấp (mức 1–3) có tỉ lệ tiểu đường cao hơn đáng kể, phản ánh mối liên hệ giữa yếu tố kinh tế xã hội và khả năng tiếp cận dinh dưỡng lành mạnh, y tế dự phòng.

3.2.6. Phân tích ma trận tương quan

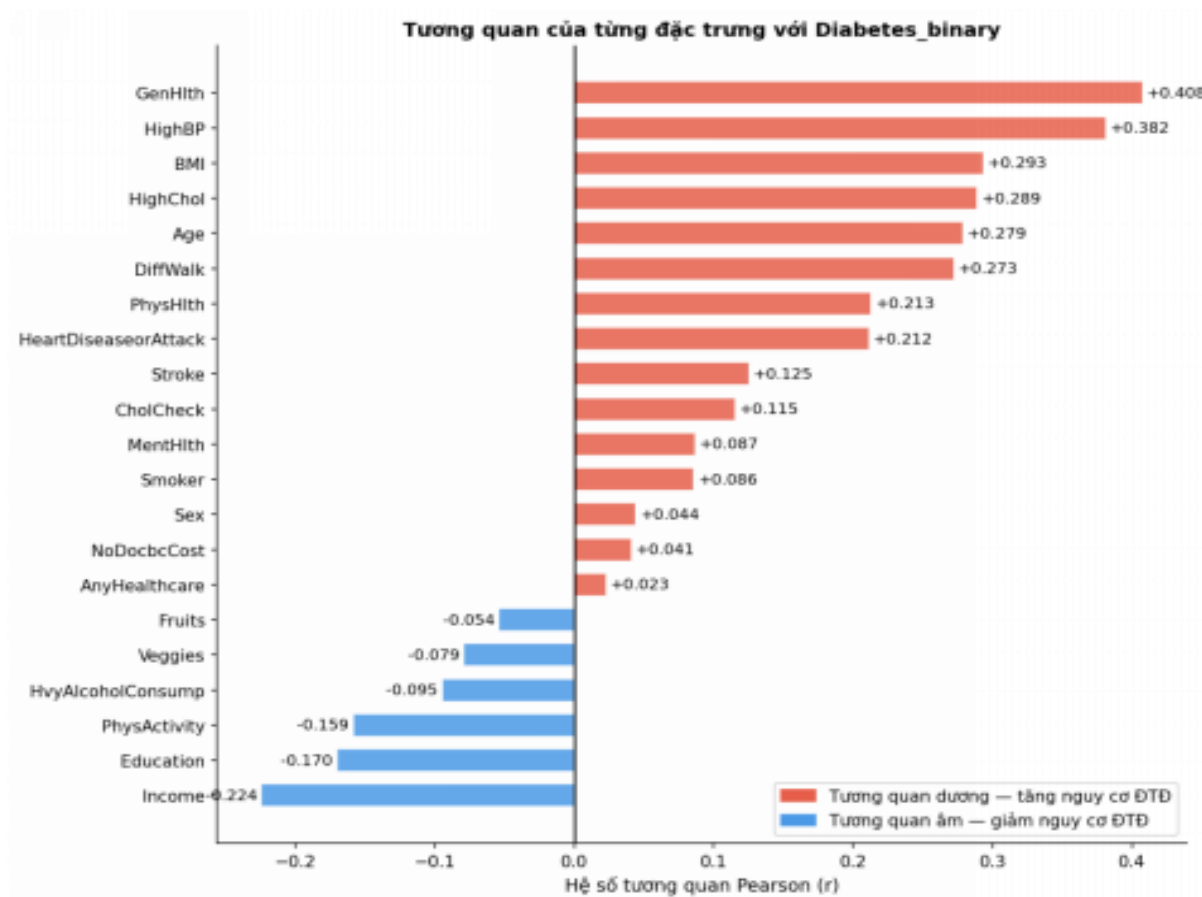
Ma trận tương quan Pearson cung cấp cái nhìn tổng thể về mối liên hệ tuyến tính giữa tất cả các cặp biến trong tập dữ liệu, từ đó hỗ trợ việc phát hiện đặc trưng có ý nghĩa dự báo và kiểm tra hiện tượng đa cộng tuyến có thể ảnh hưởng đến hiệu năng mô hình.



Hình 3.5. Ma trận tương quan Pearson giữa 22 biến trong tập dữ liệu.

Phân tích hình 3.5 cho thấy một số mối tương quan đáng chú ý. HighBP và HighChol có hệ số tương quan $r \approx 0.21$, phản ánh sự đồng thời xuất hiện phổ biến của huyết áp cao và cholesterol cao trong hội chứng chuyển hóa. GenHlth tương quan đáng kể với DiffWalk, PhysHlth và MentHlth, cho thấy người tự đánh giá sức khỏe kém thường có nhiều ngày không khỏe và khó khăn vận động. Biến Age tương quan dương với HighBP và HeartDiseaseorAttack, phản ánh sự tích lũy bệnh lý theo độ tuổi. Đáng

khen là không phát hiện cặp biến nào có hệ số tương quan vượt quá 0.5 — ngưỡng thường được xem là dấu hiệu đa cộng tuyến đáng lo ngại — điều này đảm bảo tính ổn định cho cả mô hình tuyến tính (Logistic Regression) và phi tuyến (Random Forest, XGBoost).



Hình 3.6. Hệ số tương quan Pearson của từng đặc trưng với biến mục tiêu *Diabetes_binary*.

Hình 3.6 trực quan hóa mức độ liên quan của từng đặc trưng đến biến mục tiêu. Nhóm tương quan dương mạnh nhất bao gồm: GenHlth ($r = +0.408$), HighBP ($r = +0.382$), BMI ($r = +0.293$), HighChol ($r = +0.289$) và Age ($r = +0.279$). Đây là năm đặc trưng được kỳ vọng sẽ có tầm quan trọng cao trong quá trình xây dựng và giải thích mô hình ở các chương sau. Ngược lại, nhóm tương quan âm gồm Income ($r = -0.224$), Education ($r = -0.171$) và PhysActivity ($r = -0.159$), cho thấy rằng thu nhập cao, học vấn cao và vận động nhiều là các yếu tố bảo vệ làm giảm nguy cơ tiểu đường. Quan sát này nhất quán với nhiều nghiên cứu dịch tễ học về vai trò của yếu tố kinh tế xã hội trong sức khỏe cộng đồng.

3.3. Đánh giá chất lượng dữ liệu

3.3.1. Kiểm tra giá trị thiếu (*Missing Values*)


Kết quả kiểm tra dữ liệu cho thấy tập dữ liệu không tồn tại giá trị thiếu ở bất kỳ biến nào, với tỷ lệ missing bằng 0% trên toàn bộ 22 cột và 70.692 hàng. Điều này cho thấy dữ liệu BRFSS 2015 đã được thu thập và làm sạch một cách nghiêm ngặt trước khi công bố. Về mặt kỹ thuật, không cần thực hiện thêm các bước xử lý khuyết thiếu như imputation hay loại bỏ mẫu, giúp đơn giản hóa đáng kể quy trình tiền xử lý và đảm bảo tính toàn vẹn của dữ liệu đầu vào. Tuy nhiên, mặc dù không phát hiện giá trị thiếu trong tập dữ liệu hiện tại, bước kiểm tra missing value vẫn nên được duy trì trong pipeline xử lý dữ liệu để đảm bảo tính ổn định khi hệ thống vận hành với dữ liệu mới.

3.3.2. Kiểm tra hàng trùng lặp

Quá trình kiểm tra phát hiện 1.635 hàng có giá trị hoàn toàn giống nhau trên tất cả 22 cột, chiếm tỷ lệ 2.31% tổng số mẫu. Do dữ liệu BRFSS là khảo sát tự báo cáo với thang đo rời rạc, sự trùng lặp có thể xuất hiện do nhiều người thực sự có cùng hồ sơ sức khỏe, hoặc do quá trình undersampling/resampling khi tạo phiên bản 50/50. Để đảm bảo tính độc lập của các mẫu huấn luyện và tránh overfitting, những hàng trùng lặp này sẽ được loại bỏ trong bước tiền xử lý dữ liệu (Chương 5).

3.3.3. Phân tích ngoại lai (*Outlier Detection*)

Phương pháp IQR (Interquartile Range) được áp dụng để xác định các giá trị nằm ngoài khoảng phân phối trung tâm. Theo đó, IQR được tính bằng công thức $IQR = Q3 - Q1$, và một giá trị được xem là ngoại lai nếu nằm ngoài khoảng $[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$. Phân tích tập trung vào ba biến có biên độ giá trị rộng: BMI, MentHlth và PhysHlth.



Hình 3.7. Boxplot phân tích ngoại lai cho BMI, Sức khỏe tâm thần và Sức khỏe thể chất..

Đường cam trong hình 3.7 là ngưỡng IQR xác định.

Bảng 3.4. Kết quả phân tích ngoại lai theo phương pháp IQR.

Biến	Q1	Q2	IQR	Ngưỡng dưới	Ngưỡng trên	Số ngoại lai	Tỉ lệ	Nhận xét
BMI	25.0	33.0	8.0	13.0	45.0	2,181	3.09%	Cần IQR clipping (giữ, không xóa)
MentHlth	0.0	2.0	2.0	-3.0	5.0	11,816	16.71%	Zero-inflated; hợp lệ về y tế, giữ nguyên
PhysHlth	0.0	6.0	6.0	-9.0	15.0	10,624	15.03%	Tương tự MentHlth, không cần xóa

Từ hình 3.7 và bảng 3.4, kết quả phân tích cho thấy ba trường hợp cần xử lý khác nhau. Đối với BMI, 2.181 mẫu (3.09%) có giá trị vượt ngưỡng 45 — một số trường hợp đạt đến mức 98, là giá trị rất bất thường trong thực tế. Mặc dù béo phì cực độ có thể tồn tại, các giá trị cực cao này có thể làm mô hình bị ảnh hưởng. Chiến lược được khuyến nghị là IQR clipping — giữ lại mẫu nhưng giới hạn giá trị về ngưỡng trên 45 — thay vì xóa để tránh mất thông tin. Đối với MentHlth và PhysHlth, tỉ lệ ngoại lai theo IQR lên đến 16.71% và 15.03% một cách tương ứng. Tuy nhiên, điều này là do đặc điểm zero-inflated của hai biến này — IQR rất hẹp (chỉ 2 và 6) khiến bất kỳ giá trị nào vượt ngưỡng thấp đều bị đánh dấu là ngoại lai. Trên thực tế, thang đo 0–30 ngày là hoàn toàn hợp lệ theo thiết kế khảo sát và phản ánh thực tế lâm sàng, do đó không nên xóa những giá trị này.

3.3.4. Kiểm tra tính nhất quán dữ liệu

Kiểm tra tính nhất quán xác nhận rằng tất cả 14 biến nhị phân chỉ nhận giá trị trong tập {0, 1}; biến GenHlth nằm trong khoảng {1, 2, 3, 4, 5}; biến Age nằm trong khoảng {1, ..., 13}; biến Education nằm trong khoảng {1, ..., 6}; biến Income nằm trong khoảng {1, ..., 8}; và hai biến MentHlth, PhysHlth đều nằm trong khoảng [0, 30] theo đúng thiết kế khảo sát. Tất cả 22 biến được lưu dưới dạng float64, kể cả các biến nhị phân — điều này không gây lỗi tính toán nhưng nên được ép kiểu về int hoặc category trong pipeline để tối ưu bộ nhớ và đúng ngữ nghĩa dữ liệu.

3.4. Nhận xét rút ra từ phân tích EDA

Quá trình phân tích khám phá dữ liệu (EDA) đã cung cấp bức tranh toàn diện về đặc điểm, chất lượng và tiềm năng dự báo của tập dữ liệu BRFSS 2015. Những phát hiện chính được tổng hợp như sau:

Dữ liệu có chất lượng cao với 0% giá trị thiếu, kiểu dữ liệu nhất quán và thang đo đúng quy ước trên toàn bộ 22 biến. Không cần áp dụng imputation hay encoding phức tạp.

Tỉ lệ lớp cân bằng hoàn hảo 50/50 với 35.346 mẫu mỗi lớp. Điều này cho phép sử dụng Accuracy làm metric chính bên cạnh F1-score và ROC-AUC, đồng thời không cần áp dụng SMOTE hay class weighting trong pipeline.

Top 5 đặc trưng có tương quan dương mạnh nhất với tiểu đường: GenHlth ($r=+0.41$), HighBP ($r=+0.38$), BMI ($r=+0.29$), HighChol ($r=+0.29$) và Age ($r=+0.28$). Đây là những biến được kỳ vọng có tầm quan trọng cao trong mô hình học máy.

Yếu tố bảo vệ (tương quan âm): Thu nhập cao ($r=-0.22$), học vấn cao ($r=-0.17$) và vận động thể chất ($r=-0.16$) làm giảm nguy cơ tiểu đường — phản ánh vai trò quan trọng của điều kiện kinh tế xã hội và lối sống lành mạnh.

Không phát hiện đa cộng tuyến nghiêm trọng (không có cặp biến nào có $|r| > 0.5$), đảm bảo tính ổn định cho cả mô hình tuyến tính và phi tuyến.

Phát hiện 1.635 hàng trùng lặp (2.31%) cần được loại bỏ trước khi huấn luyện. BMI có 3.09% ngoại lai cần xử lý bằng IQR clipping (cap về 45). MentHlth và PhysHlth có tỉ lệ "ngoại lai IQR" cao nhưng hợp lệ về mặt y tế — giữ nguyên.

Những phát hiện từ EDA sẽ là cơ sở trực tiếp cho các quyết định thiết kế ở Chương 5 (Tiền xử lý dữ liệu): loại bỏ hàng trùng lặp, IQR clipping cho BMI, chuẩn hóa các biến liên tục bằng StandardScaler khi sử dụng Logistic Regression, và ép kiểu dữ liệu phù hợp cho các biến nhị phân.

CHƯƠNG 4. TIỀN XỬ LÝ DỮ LIỆU

4.1. Mục tiêu tiền xử lý

Tiền xử lý dữ liệu là bước nền tảng và có vai trò quyết định đến chất lượng của toàn bộ quá trình xây dựng mô hình học máy. Mục tiêu tổng quát của giai đoạn này là chuyển đổi dữ liệu thô từ nguồn thu thập ban đầu sang dạng cấu trúc sạch, nhất quán và phù hợp để đưa vào huấn luyện các thuật toán phân loại.

Cụ thể, quá trình tiền xử lý trong nghiên cứu này hướng đến ba mục tiêu chính:

- Thứ nhất, đảm bảo tính toàn vẹn và độ tin cậy của dữ liệu thông qua việc phát hiện và xử lý các giá trị bất thường, dữ liệu thiếu hoặc không hợp lệ.
- Thứ hai, đưa các đặc trưng về cùng một thang đo phù hợp nhằm tránh hiện tượng một số đặc trưng có giá trị lớn áp đảo quá trình học của mô hình.
- Thứ ba, đảm bảo phân phối cân bằng giữa các nhãn lớp, từ đó giúp mô hình học được tri thức đồng đều và không bị thiên lệch về phía lớp chiếm đa số.

Bộ dữ liệu được sử dụng trong nghiên cứu này là BRFSS 2015 (Behavioral Risk Factor Surveillance System) phiên bản đã được lọc và cân bằng nhãn, gồm 70.692 mẫu quan sát với 21 đặc trưng đầu vào và 1 nhãn mục tiêu nhị phân (Diabetes_binary). Các đặc trưng bao gồm các chỉ số sức khỏe dạng nhị phân (0/1) như HighBP, HighChol, Smoker, Stroke... và các chỉ số dạng số nguyên như BMI, Age, GenHlth, MentHlth, PhysHlth, Education, Income.

4.2. Các bước tiền xử lý

Quy trình tiền xử lý được thực hiện tuần tự qua ba bước chính:

- (1) làm sạch dữ liệu.
- (2) chuẩn hóa và biến đổi dữ liệu.
- (3) xử lý mất cân bằng dữ liệu.

Mỗi bước được thiết kế dựa trên đặc điểm cụ thể của bộ dữ liệu BRFSS 2015 và yêu cầu của các thuật toán phân loại được lựa chọn.

4.2.1. Làm sạch dữ liệu

Làm sạch dữ liệu là bước đầu tiên và mang tính nền tảng trong quy trình tiền xử lý, nhằm đảm bảo rằng dữ liệu đưa vào mô hình không chứa các giá trị không hợp lệ, mâu thuẫn hoặc gây nhiễu cho quá trình học. Trong thực tiễn, dữ liệu thu thập từ các cuộc khảo sát sức khỏe thường gặp các vấn đề phổ biến như: giá trị bị thiếu (missing values) do người tham gia bỏ qua câu hỏi, giá trị ngoại lệ (outliers) do nhập liệu sai hoặc trường hợp cực đoan về mặt sinh lý, và dữ liệu trùng lặp (duplicates) làm sai lệch phân phối huấn luyện.

Các kỹ thuật xử lý phổ biến được áp dụng tùy theo tình huống cụ thể bao gồm: loại bỏ hoặc điền giá trị thiếu bằng trung bình, trung vị hoặc mode của cột tương ứng; lọc và xử lý ngoại lệ dựa trên phân vị (IQR method) hoặc theo ngưỡng miền tri thức; và loại bỏ các dòng trùng lặp hoàn toàn.

Đối với bộ dữ liệu BRFSS 2015 được sử dụng trong nghiên cứu này, sau khi tiến hành kiểm tra toàn diện, kết quả cho thấy toàn bộ 70.692 mẫu quan sát đều có đầy đủ giá trị trên tất cả 22 cột (21 đặc trưng và 1 nhãn mục tiêu), không tồn tại bất kỳ giá trị thiếu hay dòng trùng lặp nào. Điều này phản ánh đây là phiên bản dữ liệu đã được tiền xử lý sơ bộ bởi tổ chức CDC (Centers for Disease Control and Prevention) trước khi công bố. Toàn bộ các giá trị sau khi ép kiểu sang dạng số đều hợp lệ, và nhãn mục tiêu chỉ nhận hai giá trị 0.0 và 1.0 đúng theo định dạng nhị phân yêu cầu.

Mặc dù bộ dữ liệu đã đạt yêu cầu về tính toàn vẹn, bước làm sạch dữ liệu vẫn được thực hiện đầy đủ theo quy trình chuẩn bao gồm kiểm tra missing values, kiểm tra kiểu dữ liệu từng cột, xác minh miền giá trị của nhãn mục tiêu, và loại bỏ dữ liệu không hợp lệ. Các kiểm tra này được mã hóa tường minh trong đoạn xử lý trước khi phân chia tập huấn luyện và kiểm thử, đảm bảo quy trình có thể tái sử dụng và kiểm chứng được khi áp dụng với dữ liệu mới trong tương lai.

Bảng 4.1. Tóm tắt kết quả kiểm tra chất lượng dữ liệu.

Tiêu chí kiểm tra	Kết quả	Hành động
Giá trị thiếu (Missing values)	0 / 70.692 mẫu	Không cần xử lý

Dữ liệu trùng lặp (Duplicates)	1635 dòng	Không cần xử lý
Kiểu dữ liệu các cột	Tất cả kiểu float64	Ép sang kiểu số (to_numeric)
Giá trị hợp lệ sau ép kiểu	0 giá trị NaN phát sinh	Không cần xử lý
Miền giá trị nhãn mục tiêu	Chỉ gồm {0.0, 1.0}	Không cần xử lý

4.2.2. Chuẩn hóa và biến đổi dữ liệu

Chuẩn hóa dữ liệu (feature scaling) là bước biến đổi các đặc trưng đầu vào về cùng một thang đo, nhằm đảm bảo rằng các thuật toán học máy không bị ảnh hưởng bởi sự chênh lệch đơn vị hoặc phạm vi giá trị giữa các đặc trưng. Bước này đặc biệt quan trọng đối với các mô hình dựa trên khoảng cách (như K-Nearest Neighbors) hoặc mô hình tối ưu bằng gradient (như Logistic Regression), trong khi các mô hình dựa trên cây quyết định (Decision Tree, Random Forest, Gradient Boosting) thường không bị ảnh hưởng bởi thang đo đặc trưng.

Hai phương pháp chuẩn hóa được sử dụng phổ biến nhất trong học máy là Min-Max Scaling và Standard Scaling (Z-score Normalization). Min-Max Scaling biến đổi dữ liệu về khoảng $[0, 1]$ theo công thức $x' = (x - x_{\min}) / (x_{\max} - x_{\min})$, phù hợp khi phân phối dữ liệu không tuân theo phân phối chuẩn và không có ngoại lệ cực đoan. Standard Scaling (Z-score) biến đổi dữ liệu về phân phối có trung bình bằng 0 và độ lệch chuẩn bằng 1 theo công thức $x' = (x - \mu) / \sigma$, phù hợp hơn khi dữ liệu có ngoại lệ hoặc khi các thuật toán giả định phân phối chuẩn.

Trong nghiên cứu này, sau khi phân tích đặc điểm phân phối của từng đặc trưng trong bộ dữ liệu BRFSS 2015, phương pháp Standard Scaling (StandardScaler của thư viện scikit-learn) được lựa chọn áp dụng cho các mô hình nhạy cảm với thang đo đặc trưng, cụ thể là Logistic Regression, K-Nearest Neighbors. Lý do lựa chọn Standard Scaling thay vì Min-Max Scaling là do một số đặc trưng như BMI (min=12, max=98)

và MentHlth (min=0, max=30) có phạm vi giá trị rộng và phân phối lệch; Standard Scaling xử lý tốt hơn trong các trường hợp như vậy. Các mô hình dựa trên cây (Decision Tree, Random Forest, Gradient Boosting) không yêu cầu chuẩn hóa do cơ chế phân chia ngưỡng của chúng không phụ thuộc vào giá trị tuyệt đối của đặc trưng.

Một lưu ý quan trọng trong thực thi là StandardScaler chỉ được fit trên tập huấn luyện (X_train) rồi transform lên cả tập huấn luyện lẫn tập kiểm thử (X_test). Nguyên tắc này ngăn hiện tượng data leakage - tức là tránh để thông tin thống kê của tập kiểm thử ảnh hưởng đến quá trình huấn luyện, đảm bảo kết quả đánh giá phản ánh đúng khả năng khái quát hóa của mô hình trên dữ liệu chưa thấy.

Bảng 4.2. So sánh hai phương pháp chuẩn hóa và lý do lựa chọn.

Tiêu chí	Min-Max Scaling	Standard Scaling (Z-score)
Công thức	$x' = \frac{x - \min}{\max - \min}$	$x' = \frac{x - \mu}{\sigma}$
Khoảng giá trị đầu ra	[0, 1]	Không giới hạn ($\mu=0, \sigma=1$)
Xử lý ngoại lệ	Kém – bị kéo về hai đầu	Tốt hơn – ít bị ảnh hưởng
Phù hợp với	Dữ liệu phân phối đều, ít ngoại lệ	Dữ liệu có phân phối lệch, ngoại lệ
Áp dụng trong nghiên cứu	Không chọn	Chọn (LR, KNN, SVM)

4.2.3. Xử lý mất cân bằng dữ liệu

Mất cân bằng dữ liệu (class imbalance) là một vấn đề phổ biến và nghiêm trọng trong các bài toán phân loại nhị phân liên quan đến y tế, đặc biệt là phát hiện bệnh. Trong các tập dữ liệu thu thập tự nhiên, tỷ lệ người mắc bệnh thường chiếm thiểu số so với người không mắc bệnh, dẫn đến tình trạng mô hình học máy có xu hướng dự đoán

lớp đa số (không mắc bệnh) cho hầu hết các mẫu và bỏ sót phần lớn các ca dương tính thực sự, đây là sai lầm có chi phí cao nhất trong bối cảnh y tế.

Các kỹ thuật xử lý mất cân bằng thường được ứng dụng bao gồm ba nhóm chính. Nhóm thứ nhất là các phương pháp lấy mẫu lại (resampling): oversampling lớp thiểu số bằng SMOTE (Synthetic Minority Oversampling Technique) hoặc Random Oversampling, và undersampling lớp đa số bằng Random Undersampling hoặc NearMiss. Nhóm thứ hai là điều chỉnh trọng số lớp (class_weight) trong các thuật toán, cho phép mô hình phạt nặng hơn khi dự đoán sai lớp thiểu số. Nhóm thứ ba là sử dụng các chỉ số đánh giá phù hợp như Recall, F1-score, AUC-ROC thay vì chỉ dùng Accuracy.

Bộ dữ liệu BRFSS 2015 phiên bản được sử dụng trong nghiên cứu này là phiên bản đã được cân bằng nhãn thông qua kỹ thuật undersampling ngẫu nhiên trên tập dữ liệu gốc - cụ thể là phiên bản "50/50 split" được công bố trên nền tảng Kaggle. Kết quả là tỷ lệ phân phối nhãn đạt mức hoàn toàn cân bằng: lớp 0 (không mắc bệnh tiểu đường) gồm 35.346 mẫu và lớp 1 (mắc bệnh tiểu đường) gồm 35.346 mẫu, mỗi lớp chiếm đúng 50% tổng số quan sát.

Việc chủ động lựa chọn phiên bản dữ liệu đã cân bằng mang lại các lợi ích đáng kể. Trước tiên, mô hình được huấn luyện trên phân phối đồng đều sẽ không bị thiên lệch về phía lớp chiếm đa số, từ đó cải thiện khả năng phát hiện ca dương tính thực sự - là mục tiêu cốt lõi trong bài toán chẩn đoán bệnh tiểu đường. Ngoài ra, việc sử dụng dữ liệu cân bằng đơn giản hóa quá trình thực nghiệm, tránh phải áp dụng thêm các kỹ thuật lấy mẫu phức tạp vốn có thể gây ra overfitting (oversampling) hoặc mất thông tin (aggressive undersampling). Đồng thời, kết quả đánh giá mô hình trên tập kiểm thử cân bằng phản ánh chính xác hơn hiệu năng thực sự của từng thuật toán thay vì bị làm nhiễu bởi sự chênh lệch tần suất nhãn.

Mặc dù dữ liệu đã cân bằng, trong nghiên cứu này chỉ số Recall trên lớp dương (class 1 - mắc bệnh) vẫn được chọn là chỉ số tối ưu chính trong GridSearchCV. Lý do là trong thực tế triển khai lâm sàng, chi phí của việc bỏ sót một ca dương tính thực sự (False Negative) luôn cao hơn nhiều so với chi phí cảnh báo nhầm một ca âm tính (False Positive). Việc tối ưu Recall đảm bảo mô hình được lựa chọn có độ nhạy cao nhất với ca mắc bệnh, phù hợp với mục tiêu y tế dự phòng của bài toán.

Bảng 4.3. Tóm tắt thông tin phân phối nhãn trong bộ dữ liệu sử dụng.

Nhãn (Diabetes_binary)	Ý nghĩa	Số mẫu	Tỷ lệ
0	Không mắc bệnh tiểu đường	35.346	50,0%
1	Mắc bệnh tiểu đường	35.346	50,0%
Tổng cộng		70.692	100,0%

CHƯƠNG 5. HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH

5.1. Môi trường huấn luyện

Để đảm bảo tính tái tạo và nhất quán của thực nghiệm, toàn bộ quá trình huấn luyện và đánh giá mô hình được thực hiện trong một môi trường được cấu hình cố định với hạt giống ngẫu nhiên (`random_state = 42`). Phần này mô tả chi tiết cấu hình phần cứng, hệ điều hành và bộ thư viện được sử dụng trong nghiên cứu.

5.1.1. Phần cứng và phần mềm

Thực nghiệm được triển khai trên máy tính cá nhân sử dụng bộ xử lý trung tâm (CPU), không sử dụng GPU hay các cụm tính toán phân tán. Đây là lựa chọn phù hợp với quy mô của bộ dữ liệu BRFSS 2015 (70.692 mẫu, 21 đặc trưng) và bộ các thuật toán học máy cổ điển được áp dụng trong nghiên cứu, vốn không yêu cầu tài nguyên tính toán song song ở mức cao.

5.1.2. Thư viện sử dụng

Toàn bộ pipeline thực nghiệm được xây dựng bằng Python và các thư viện mã nguồn mở trong hệ sinh thái khoa học dữ liệu. Bảng 5.2 liệt kê các thư viện chính và vai trò của từng thư viện trong nghiên cứu.

Bảng 5.1. Danh sách thư viện sử dụng trong thực nghiệm.

Thư viện	Phiên bản	Vai trò
scikit-learn	≥ 1.0	Xây dựng pipeline, huấn luyện mô hình, đánh giá, GridSearchCV
pandas	≥ 1.3	Đọc, xử lý và phân tích dữ liệu dạng bảng
numpy	≥ 1.21	Tính toán ma trận số, xử lý mảng đa chiều
joblib	≥ 1.0	Lưu và tải mô hình đã huấn luyện dưới dạng tệp .pkl

json / pathlib	Thư viện chuẩn	Quản lý metadata, đường dẫn tệp và xuất kết quả
-------------------	-------------------	---

5.2. Huấn luyện mô hình

Quá trình huấn luyện được thiết kế theo quy trình chuẩn trong học máy, đảm bảo tính khách quan và khả năng so sánh công bằng giữa các thuật toán. Bộ dữ liệu sau tiền xử lý được phân chia thành tập huấn luyện (training set) và tập kiểm thử (test set) theo tỷ lệ 80:20 với chiến lược phân tầng (stratified split) nhằm duy trì tỷ lệ nhãn 50:50 trong cả hai tập. Cụ thể, tập huấn luyện gồm 56.553 mẫu và tập kiểm thử gồm 14.139 mẫu.

Nghiên cứu tiến hành huấn luyện và so sánh sáu thuật toán học máy thuộc các nhóm mô hình khác nhau: Logistic Regression (mô hình tuyến tính), Decision Tree (cây quyết định đơn), Random Forest và Gradient Boosting (phương pháp ensemble), K-Nearest Neighbors (dựa trên khoảng cách). Mỗi thuật toán được tích hợp trong một scikit-learn Pipeline, đảm bảo bước chuẩn hóa dữ liệu (StandardScaler) chỉ được fit trên tập huấn luyện và không gây rò rỉ thông tin sang tập kiểm thử.

Để lựa chọn siêu tham số tối ưu cho từng thuật toán, phương pháp tìm kiếm lưới (GridSearchCV) được áp dụng với kiểm định chéo 3 fold (3-fold cross-validation) trên tập huấn luyện, sử dụng chỉ số Recall làm tiêu chí tối ưu. Việc tối ưu theo Recall phản ánh ưu tiên của bài toán: trong chẩn đoán bệnh tiểu đường, bỏ sót một ca dương tính thực sự (False Negative) gây hậu quả nghiêm trọng hơn nhiều so với cảnh báo nhầm. Bảng 5.3 trình bày không gian tìm kiếm siêu tham số và kết quả tốt nhất được chọn cho từng mô hình.

Bảng 5.2. Không gian tìm kiếm siêu tham số và kết quả GridSearchCV.

Mô hình	Siêu tham số tìm kiếm	Giá trị tốt nhất (best params)
Logistic Regression	$C \in \{0.1, 1, 10\}$	$C = 1, \text{ solver} = \text{lbfgs}$

Decision Tree	$\text{max_depth} \in \{5,10,20\};$ $\text{min_samples_split} \in \{2,5,10\}$	$\text{max_depth} = 5,$ $\text{min_samples_split} = 2$
Random Forest	$\text{n_estimators} \in \{100,200\};$ $\text{max_depth} \in \{10,20,\text{None}\};$ $\text{min_samples_split} \in \{2,5\}$	$\text{n_estimators}=100,$ $\text{max_depth}=10,$ $\text{min_samples_split}=5$
Gradient Boosting	$\text{n_estimators} \in \{100,200\};$ $\text{learning_rate} \in \{0.05,0.1\};$ $\text{max_depth} \in \{3,5\}$	$\text{n_estimators}=200,$ $\text{learning_rate}=0.05,$ $\text{max_depth}=5$
K-Nearest Neighbors	$\text{n_neighbors} \in \{5,7,11\};$ $\text{weights} \in \{\text{uniform}, \text{distance}\}$	$\text{n_neighbors}=11,$ $\text{weights}=\text{uniform}$

Sau khi GridSearchCV xác định bộ siêu tham số tối ưu, mỗi mô hình được tái huấn luyện trên toàn bộ tập huấn luyện (56.553 mẫu) với bộ tham số đó. Các mô hình đã huấn luyện được lưu lại dưới định dạng .pkl bằng thư viện joblib, phục vụ cho quá trình đánh giá và triển khai sau này. Toàn bộ kết quả tổng hợp được ghi vào tệp model_results.csv cùng với metadata chi tiết về quá trình thực nghiệm.

5.3. Đánh giá kết quả

Sau khi hoàn thành huấn luyện, các mô hình được đánh giá trên tập kiểm thử độc lập (14.139 mẫu) chưa tham gia vào bất kỳ giai đoạn huấn luyện hay lựa chọn tham số nào. Bốn chỉ số đánh giá chính được sử dụng: Accuracy (độ chính xác tổng thể), Recall (độ nhạy - tỷ lệ phát hiện đúng ca dương tính), Precision (độ đặc hiệu dương - tỷ lệ dự đoán dương tính là đúng) và F1-Score (trung bình điều hòa của Recall và Precision). Ngoài ra, chỉ số AUC-ROC (diện tích dưới đường cong ROC) được tính để phản ánh khả năng phân biệt tổng thể của mô hình độc lập với ngưỡng quyết định.

Bảng 5.3. Kết quả đánh giá các mô hình trên tập kiểm thử ($n = 14.139$).

Mô hình	Accuracy	Recall	Precision	F1-Score	AUC-ROC
---------	----------	--------	-----------	----------	---------

Logistic Regression	0.7458	0.7639	0.7372	0.7503	0.8232
Decision Tree	0.7306	0.7748	0.7119	0.7420	0.8058
Random Forest	0.7482	0.7926	0.7279	0.7589	0.8268
Gradient Boosting	0.7516	0.7970	0.7306	0.7624	0.8304
K-Nearest Neighbors	0.7273	0.7625	0.7123	0.7365	0.7947

Bảng 5.4 dưới đây trình bày chi tiết ma trận nhầm lẫn (Confusion Matrix) của từng mô hình, phản ánh số lượng cụ thể các trường hợp dự đoán đúng và sai theo từng nhãn lớp.

Bảng 5.4. Chi tiết ma trận nhầm lẫn (Confusion Matrix) của từng mô hình.

Mô hình	TN	FP	FN	TP
Logistic Regression	5.145	1.925	1.669	5.400
Decision Tree	4.853	2.217	1.592	5.477
Random Forest	4.976	2.094	1.466	5.603
Gradient Boosting	4.993	2.077	1.435	5.634
K-Nearest Neighbors	4.893	2.177	1.679	5.390

Dưới đây là phân tích chi tiết kết quả của từng mô hình:

Logistic Regression đạt Accuracy 74,58%, Recall 76,39% và AUC-ROC 0,8232. Đây là mô hình tuyến tính đơn giản nhất trong nhóm, nhưng cho thấy khả năng tổng quát hóa ổn định với tỷ lệ False Negative là 1.669 ca - thấp hơn KNN và Decision Tree. Điểm mạnh của mô hình này là khả năng diễn giải (interpretability) cao thông qua hệ số

hồi quy, phù hợp cho các bài toán cần giải thích kết quả dự đoán cho chuyên gia y tế. Tuy nhiên, do giả định tuyến tính, mô hình bị hạn chế trong việc nắm bắt các mối quan hệ phi tuyến phức tạp giữa các đặc trưng sức khỏe.

Decision Tree đạt Recall 77,48% - cao hơn Logistic Regression và KNN - nhưng Accuracy và F1-Score lần lượt chỉ đạt 73,06% và 74,20%, thấp nhất trong nhóm (trừ KNN về Accuracy). Mô hình có xu hướng tăng Recall bằng cách chấp nhận nhiều False Positive hơn (2.217 ca), dẫn đến Precision thấp nhất (71,19%). Với $\text{max_depth} = 5$, cây quyết định đã được kiểm soát độ phức tạp để tránh overfitting, nhưng cũng giới hạn khả năng phân loại với dữ liệu nhiều chiều. AUC-ROC đạt 0,8058, thấp hơn các mô hình ensemble.

Random Forest đạt kết quả cân bằng và tốt với Accuracy 74,82%, Recall 79,26%, F1-Score 75,89% và AUC-ROC 0,8268. Mô hình ensemble kết hợp 100 cây quyết định với $\text{max_depth} = 10$ cho thấy khả năng khái quát hóa tốt hơn đáng kể so với cây đơn lẻ. Số lượng False Negative được giảm xuống còn 1.466 ca, phản ánh độ nhạy cao trong phát hiện ca mắc bệnh. Random Forest cũng có tính ổn định cao hơn Decision Tree do cơ chế bagging và lấy mẫu ngẫu nhiên đặc trưng, đồng thời cho phép đánh giá tầm quan trọng đặc trưng (feature importance) - một lợi thế trong phân tích y tế.

Gradient Boosting đạt kết quả tốt nhất trên hầu hết các chỉ số: Accuracy 75,16%, Recall 79,70%, F1-Score 76,24% và AUC-ROC cao nhất đạt 0,8304. Đặc biệt, đây là mô hình có số lượng False Negative thấp nhất (1.435 ca) - tức là bỏ sót ít ca mắc bệnh nhất trong toàn bộ nhóm thực nghiệm. Với cấu hình $n_estimators = 200$, $learning_rate = 0,05$ và $\text{max_depth} = 5$, mô hình xây dựng tuần tự các cây quyết định yếu, mỗi cây tập trung khắc phục sai số của cây trước, từ đó tích lũy được tri thức phân loại tinh tế hơn so với Random Forest.

K-Nearest Neighbors đạt Accuracy 72,73% và F1-Score 73,65% - thấp nhất trong nhóm - tuy nhiên Recall đạt 76,25% và AUC-ROC là 0,7947. Mô hình dựa trên khoảng cách Euclidean với $n_neighbors = 11$ nhạy cảm với phân phối dữ liệu và chi phí dự đoán cao khi tập dữ liệu lớn do phải tính khoảng cách đến toàn bộ tập huấn luyện. Điểm yếu chính của KNN trong bài toán này là khả năng phân biệt giữa các vùng quyết định phức tạp bị hạn chế, phản ánh qua AUC-ROC thấp nhất (0,7947) trong nhóm.

5.4. So sánh và lựa chọn mô hình

Dựa trên kết quả đánh giá toàn diện tại Bảng 5.4 và Bảng 5.5, có thể nhận thấy một số xu hướng rõ ràng trong hiệu năng của các mô hình. Các phương pháp ensemble (Random Forest và Gradient Boosting) nhất quán vượt trội so với các mô hình đơn lẻ trên tất cả các chỉ số đánh giá, trong khi K-Nearest Neighbors và Decision Tree cho kết quả thấp hơn mặc dù đã được tối ưu siêu tham số.

Dựa trên kết quả đánh giá tổng hợp trên nhiều chỉ số hiệu năng, mô hình Gradient Boosting được lựa chọn là mô hình tối ưu cho bài toán phân loại nguy cơ mắc bệnh tiểu đường trong nghiên cứu này. Quyết định lựa chọn được đưa ra dựa trên ba cơ sở quan trọng sau.

Thứ nhất, Gradient Boosting đạt giá trị Recall cao nhất, đạt 79,70%. Điều này cho thấy mô hình có khả năng phát hiện bệnh nhân mắc tiểu đường tốt nhất trong số các thuật toán được thử nghiệm, đồng thời tạo ra số lượng âm tính giả (False Negative) thấp nhất, chỉ còn 1.435 trường hợp. Trong bối cảnh bài toán y tế dự phòng, việc giảm thiểu nguy cơ bỏ sót bệnh nhân thực sự mắc bệnh có ý nghĩa đặc biệt quan trọng, do đó Recall được xem là tiêu chí ưu tiên hàng đầu trong quá trình lựa chọn mô hình.

Thứ hai, mô hình đạt chỉ số AUC-ROC cao nhất với giá trị 0,8304. Chỉ số này phản ánh khả năng phân biệt tổng quát giữa hai lớp dữ liệu — người mắc bệnh và người không mắc bệnh — trên nhiều ngưỡng phân loại khác nhau. Giá trị AUC cao cho thấy Gradient Boosting không chỉ hoạt động tốt tại một ngưỡng quyết định cụ thể mà còn duy trì được năng lực phân loại ổn định và đáng tin cậy trên toàn bộ không gian xác suất dự đoán.

Thứ ba, mô hình đồng thời đạt Accuracy và F1-score cao nhất, lần lượt là 75,16% và 76,24%. Kết quả này cho thấy Gradient Boosting không chỉ tập trung tối đa hóa Recall mà vẫn duy trì được sự cân bằng hợp lý giữa khả năng phát hiện bệnh và độ tin cậy của các cảnh báo dương tính. Nói cách khác, mô hình tránh được tình trạng tăng Recall bằng cách tạo ra quá nhiều dự đoán dương tính giả, từ đó đảm bảo hiệu quả ứng dụng thực tiễn trong môi trường hỗ trợ chẩn đoán y tế.

Bên cạnh đó, Random Forest cũng cho kết quả rất cạnh tranh với Recall đạt 79,26% và AUC-ROC đạt 0,8268, chỉ chênh lệch nhỏ so với Gradient Boosting. Điều này cho thấy Random Forest vẫn là một lựa chọn phù hợp trong những trường hợp cần tốc độ

huấn luyện và suy luận nhanh hơn hoặc khi cần phân tích trực tiếp mức độ ảnh hưởng của các đặc trưng thông qua Feature Importance. Tuy nhiên, xét trên mục tiêu ưu tiên phát hiện đúng bệnh nhân và giảm thiểu nguy cơ bỏ sót ca bệnh trong hỗ trợ chẩn đoán lâm sàng, Gradient Boosting vẫn thể hiện hiệu quả tổng thể vượt trội hơn.

Trong khi đó, Logistic Regression mặc dù là mô hình tuyến tính đơn giản nhất nhưng vẫn đạt kết quả khá tích cực với AUC-ROC đạt 0,8232, không chênh lệch quá lớn so với các mô hình ensemble. Ưu điểm nổi bật của Logistic Regression nằm ở khả năng diễn giải cao, cho phép phân tích trực tiếp mức độ ảnh hưởng của từng đặc trưng thông qua hệ số hồi quy và Odds Ratio. Điều này giúp tăng tính minh bạch của hệ thống và hỗ trợ bác sĩ hiểu rõ cơ sở mà mô hình sử dụng để đưa ra dự đoán.

CHƯƠNG 6. XÂY DỰNG HỆ THỐNG MINING

Trên cơ sở kết quả thực nghiệm tại Chương 5, chương này trình bày phương án thiết kế và vận hành một hệ thống khai phá dữ liệu hoàn chỉnh, đảm nhận toàn bộ vòng đời của mô hình từ thu nhận dữ liệu, tiền xử lý, huấn luyện, đánh giá đến cập nhật và phục vụ. Hệ thống được xây dựng theo định hướng đơn giản, có khả năng tái lập trên môi trường máy tính cá nhân, đồng thời vẫn tuân thủ các nguyên tắc cốt lõi của một quy trình MLOps thu nhỏ: phân tách rõ trách nhiệm giữa các tầng xử lý, lưu vết phiên bản dữ liệu và mô hình, áp dụng cơ chế Champion – Challenger (mô hình đang phục vụ – mô hình mới huấn luyện) để kiểm soát chất lượng khi cập nhật.

6.1. Kiến trúc hệ thống

Hệ thống được tổ chức theo mô hình kiến trúc phân lớp, gồm năm tầng độc lập về chức năng nhưng liên kết chặt chẽ thông qua các khu vực dữ liệu trung gian. Sự phân tách này đảm bảo mỗi thành phần có thể được kiểm thử, thay thế hoặc nâng cấp riêng biệt mà không ảnh hưởng tới các tầng còn lại, đồng thời tạo cơ sở để hệ thống dễ dàng mở rộng sang môi trường vận hành thực tế hoặc nền tảng điện toán đám mây trong tương lai.

6.1.1. Sơ đồ kiến trúc tổng thể

Hình 6.1 minh họa năm tầng của hệ thống cùng các luồng dữ liệu chính giữa chúng.



Hình 6.1. Kiến trúc hệ thống dự đoán nguy cơ bệnh tiểu đường.

6.1.2. Vai trò của từng tầng

Tầng Dữ liệu đảm nhận vai trò là nguồn cung cấp dữ liệu duy nhất cho toàn bộ hệ thống. Tầng này quản lý hai nhóm dữ liệu song song: tập dữ liệu nền BRFSS 2015 đã cân bằng nhãn (đóng vai trò bộ huấn luyện cốt lõi) và khu vực tiếp nhận các lô dữ liệu khảo sát mới được người vận hành bổ sung trong quá trình triển khai. Đi kèm là một hồ sơ dữ liệu nền – tài liệu ghi nhận khung tham chiếu về cấu trúc cột, kiểu dữ liệu, miền giá trị và các thông kê cơ bản (giá trị nhỏ nhất, lớn nhất, trung bình) của từng đặc trưng tại thời điểm khởi tạo phiên bản mô hình đầu tiên. Hồ sơ này đóng vai trò mốc so chiếu để phát hiện những thay đổi bất thường khi hệ thống tiếp nhận dữ liệu mới.

Tầng Xử lý chịu trách nhiệm chuyển hóa dữ liệu thô thành ma trận đặc trưng đầu vào cho mô hình. Tầng này thực hiện tuần tự các bước: đối chiếu cấu trúc dữ liệu mới với hồ sơ nền để phát hiện cột thiếu hoặc cột phát sinh ngoài quy ước, kiểm tra trôi dữ liệu trên giá trị trung bình của từng đặc trưng số, loại bỏ các dòng trùng lặp, ép kiểu số an toàn, kiểm tra tính hợp lệ của nhãn mục tiêu, phân chia tập huấn luyện và kiểm thử theo tỷ lệ 80:20 với chiến lược phân tầng và áp dụng chuẩn hóa Z-score cho các mô hình nhảy thang đo. Toàn bộ tầng kế thừa nguyên vẹn quy trình tiền xử lý đã được trình bày tại Chương 4 nhằm đảm bảo tính nhất quán giữa quá trình huấn luyện ban đầu và các lần tái huấn luyện về sau.

Tầng Mô hình đóng vai trò trái tim của hệ thống. Tầng này thực hiện huấn luyện đồng thời năm thuật toán đã được luận giải tại Chương 2 – Logistic Regression, Decision Tree, Random Forest, Gradient Boosting và K-Nearest Neighbors – thông qua phương pháp tìm kiếm lưới kết hợp kiểm định chéo ba nếp gấp, với tiêu chí tối ưu là Recall, đồng nhất với lựa chọn ở Chương 5. Sau khi huấn luyện, tầng triển khai cơ chế Champion – Challenger: mô hình mới chỉ thay thế mô hình đang phục vụ nếu vượt qua một bài kiểm tra chất lượng dựa trên Recall, ngược lại được lưu lại trong kho phiên bản nhưng không đưa vào vận hành.

Tầng Phục vụ chịu trách nhiệm nạp Champion vào bộ nhớ và cung cấp ba dịch vụ cho tầng giao diện: dự đoán nhãn cho một mẫu, ước lượng xác suất thuộc lớp dương, và trích xuất tầm quan trọng của từng đặc trưng để giải thích quyết định. Tầng này được tối ưu bằng cơ chế bộ nhớ đệm: mô hình chỉ được nạp một lần ở phiên truy cập đầu tiên,

các yêu cầu dự đoán tiếp theo sử dụng lại bản đã nạp, qua đó giảm độ trễ phản hồi xuống mức gần thời gian thực.

Tầng Giao diện cung cấp ba trang chính phục vụ ba nhóm người dùng khác nhau: trang dự đoán dành cho người dùng cuối, trang quản trị dành cho người vận hành chịu trách nhiệm cập nhật mô hình, và trang so sánh – demo phục vụ trình bày kết quả thực nghiệm. Toàn bộ giao diện được hiện thực dưới dạng ứng dụng web tương tác chạy trên trình duyệt, đảm bảo người dùng có thể sử dụng hệ thống mà không cần cài đặt thêm phần mềm chuyên dụng.

Bên cạnh năm tầng nêu trên, hệ thống có một tầng Lưu trữ và Giám sát xuyên suốt, gồm hai khu vực: khu vực phục vụ luôn duy trì duy nhất một bản sao của Champion cùng với metadata mô tả phiên bản; và khu vực phiên bản lưu lịch sử của mọi lần tái huấn luyện, bao gồm cả các Challenger không được thay thế. Mỗi lần tái huấn luyện kèm theo một bản tóm tắt quyết định ghi rõ kết quả so sánh với phiên bản trước, giúp đảm bảo khả năng truy vết và phục hồi khi cần thiết.

6.2. Lấy dữ liệu và tiền xử lý tự động

Việc tự động hóa quy trình thu nhận và chuẩn bị dữ liệu là nền tảng để hệ thống vận hành liên tục mà không phụ thuộc vào thao tác thủ công. Phần này trình bày ba thành phần đảm bảo dữ liệu đưa vào pha huấn luyện luôn ở trạng thái sạch và nhất quán với khung tham chiếu đã thiết lập: cơ chế thu nhận dữ liệu, kiểm tra cấu trúc và phát hiện trôi dữ liệu, và quy trình tiền xử lý tự động.

6.2.1. Cơ chế thu nhận dữ liệu

Hệ thống hỗ trợ hai luồng thu nhận dữ liệu song song. Luồng mặc định đọc trực tiếp tập dữ liệu nền BRFSS 2015. Luồng bổ sung quét khu vực tiếp nhận dữ liệu mới để phát hiện các tệp khảo sát được người vận hành tải lên thông qua giao diện quản trị. Mỗi tệp bổ sung được lọc theo danh sách cột giao với khung tham chiếu trước khi được nối vào bộ dữ liệu chính, qua đó tránh tình trạng các cột phát sinh ngoài quy ước làm rối loạn các bước xử lý phía sau.

Sau khi gộp toàn bộ nguồn dữ liệu, hệ thống loại bỏ các dòng trùng lặp hoàn toàn để tránh sai lệch phân phối học. Số lượng dòng được nạp thêm và số lượng dòng bị loại

sau bước khử trùng đều được ghi lại trong metadata của lần tái huấn luyện để phục vụ truy vết.

6.2.2. Kiểm tra cấu trúc và phát hiện trôi dữ liệu

Trước khi đi vào huấn luyện, dữ liệu được kiểm tra tự động qua hai bước. Bước thứ nhất là xác thực cấu trúc: hệ thống đối chiếu danh sách cột thực tế với hồ sơ dữ liệu nền và đánh dấu hai tình huống bất thường gồm cột thiếu so với quy ước và cột phát sinh ngoài quy ước. Đồng thời, miền giá trị của nhãn mục tiêu được kiểm tra nghiêm ngặt: chỉ chấp nhận nhãn nhị phân 0 hoặc 1, ngoài ra toàn bộ chu trình tái huấn luyện sẽ dừng lại để tránh huấn luyện trên dữ liệu sai cấu trúc.

Bước thứ hai là phát hiện trôi dữ liệu cơ bản. Với mỗi đặc trưng số, hệ thống tính giá trị trung bình mới và so sánh với giá trị trung bình tại hồ sơ nền theo công thức tỷ lệ chênh lệch tương đối:

$$\text{tỷ lệ chênh} = \frac{|\text{trung bình mới} - \text{trung bình nền}|}{|\text{trung bình nền}|} \quad (12)$$

Cột nào có tỷ lệ chênh lệch vượt 15% sẽ được ghi nhận là bị trôi và đưa vào danh sách cảnh báo. Ngưỡng 15% được lựa chọn dựa trên kinh nghiệm thực hành: đủ chặt để phát hiện những thay đổi đáng kể về phân phối nhưng vẫn dung sai cho dao động ngẫu nhiên trong các lô dữ liệu nhỏ. Cảnh báo trôi dữ liệu không tự động chặn quá trình huấn luyện mà chỉ cung cấp thông tin để người vận hành đánh giá: hệ thống tiếp tục vận hành trong khi nhắc người dùng rằng nguồn dữ liệu có dấu hiệu thay đổi cấu trúc thống kê.

6.2.3. Quy trình tiền xử lý tự động

Sau khi vượt qua các bước kiểm tra, dữ liệu đi qua chuỗi tiền xử lý đã được trình bày tại Chương 4. Cụ thể, hệ thống thực hiện ép kiểu số toàn bộ đặc trưng và nhãn, kiểm tra giá trị thiếu phát sinh, phân chia tập huấn luyện – kiểm thử theo tỷ lệ 80:20 với chiến lược phân tầng để giữ cân bằng nhãn ở cả hai tập, và áp dụng chuẩn hóa Z-score chỉ trên tập huấn luyện rồi mới biến đổi tập kiểm thử. Việc đóng gói toàn bộ tiền xử lý cùng thuật toán phân loại trong một quy trình thống nhất đảm bảo nguyên tắc “học trên tập huấn luyện, áp dụng cho cả hai tập” được duy trì bền vững: ngay cả khi mô hình được lưu xuống đĩa và nạp lại ở pha dự đoán, các tham số chuẩn hóa vẫn nguyên vẹn từ tập huấn luyện gốc, không bị rò rỉ thông tin từ tập kiểm thử.

Hồ sơ dữ liệu nền cũng được tái sinh sau mỗi lần tái huấn luyện. Nếu mô hình mới được thay thế thành Champion, hồ sơ này được cập nhật và trở thành mốc tham chiếu mới cho các lần tái huấn luyện kế tiếp – một cơ chế tự thích nghi giúp hệ thống tránh được hiện tượng cảnh báo trôi giả khi phân phối dữ liệu thật sự đã dịch chuyển một cách hợp pháp theo thời gian.

6.3. Hệ thống cập nhật và tái huấn luyện liên tục

Mục tiêu của cơ chế cập nhật và tái huấn luyện là duy trì hiệu năng dự đoán của hệ thống trước hiện tượng concept drift – tình huống mối quan hệ giữa đặc trưng đầu vào và nhãn mục tiêu thay đổi theo thời gian do biến đổi về dân số, lối sống hoặc tiêu chí chẩn đoán. Phần này trình bày ba cơ chế kích hoạt tái huấn luyện, quy trình ra quyết định Champion – Challenger và cách tổ chức kho phiên bản mô hình.

6.3.1. Ba cơ chế kích hoạt tái huấn luyện

Hệ thống hỗ trợ ba phương thức kích hoạt tái huấn luyện đáp ứng các kịch bản vận hành khác nhau:

Kích hoạt thủ công: Người vận hành nhấn nút “Chạy tái huấn luyện” trên trang quản trị. Phương thức này được sử dụng trong giai đoạn trình diễn và khi cần cập nhật mô hình ngay sau khi tải lên một lô dữ liệu mới.

Kích hoạt định kỳ: Hệ thống lập lịch để tự động chạy lại quy trình theo chu kỳ cố định. Phương thức này phù hợp khi nguồn dữ liệu được bổ sung đều đặn nhưng không cần can thiệp tức thời.

Kích hoạt theo điều kiện dữ liệu: Khi số lượng dòng dữ liệu mới vượt quá một ngưỡng cho trước (ví dụ năm nghìn dòng), tác vụ định kỳ tự động kích hoạt tái huấn luyện. Cơ chế này có thể được mở rộng thêm điều kiện trôi dữ liệu: nếu số cột bị trôi vượt một ngưỡng thì hệ thống ưu tiên tái huấn luyện ngay thay vì chờ tới mốc lịch.

Ba cơ chế trên không loại trừ nhau mà bổ sung cho nhau, tạo thành một hệ thống cập nhật chủ động trong khi vẫn cho phép người vận hành can thiệp khi cần.

6.3.2. Quy trình ra quyết định Champion – Challenger

Cơ chế Champion – Challenger là trái tim của quy trình tái huấn luyện. Mỗi lần tái huấn luyện được xem là một thí nghiệm so sánh giữa mô hình đang phục vụ (Champion)

và mô hình mới được sinh ra trên dữ liệu cập nhật (Challenger). Quy trình diễn ra qua bốn bước được mô tả tại Hình 6.2.



Hình 6.2. Quy trình ra quyết định Champion - Challenger.

Tiêu chí quyết định thay thế là Recall trên tập kiểm thử của Challenger lớn hơn hoặc bằng Recall của Champion. Việc cho phép cả trường hợp bằng được thăng cấp xuất phát từ thực tế: khi Challenger được huấn luyện trên một tập dữ liệu lớn hơn (đã bao gồm dữ liệu mới) mà vẫn duy trì mức Recall, mô hình mới được cho là khái quát hóa tốt hơn trên phân phối cập nhật.

Khi quyết định thăng cấp được đưa ra, Challenger cùng các tài liệu đi kèm sẽ thay thế Champion ở khu vực phục vụ; ngược lại, Champion tiếp tục được duy trì còn Challenger vẫn được lưu trong kho phiên bản để phục vụ phân tích về sau. Trong trường hợp người vận hành cần ép buộc cập nhật bất chấp Recall (chẳng hạn để phục vụ kiểm thử), giao diện quản trị cung cấp một tùy chọn riêng cho phép bỏ qua kiểm tra chất lượng, kèm theo cảnh báo rằng tùy chọn này chỉ được dùng trong môi trường thử nghiệm.

6.3.3. Quản lý phiên bản và truy vết

Mỗi lần tái huấn luyện tạo ra một thư mục phiên bản riêng, được đánh dấu bằng thời điểm thực hiện. Thư mục này lưu lại đầy đủ dấu vết của lần tái huấn luyện, bao gồm: thời điểm chạy, số dòng dữ liệu, số dòng được bỏ sung, kết quả kiểm tra cấu trúc và trôi dữ liệu, tên thuật toán và Recall của Challenger, tên thuật toán và Recall của Champion trước đó, kết quả quyết định cùng lý do.

Cơ chế lưu vết này mang lại ba lợi ích vận hành quan trọng. Thứ nhất, khả năng truy vết: mọi quyết định cập nhật của hệ thống đều có thể được tái dựng và kiểm tra ngược dựa trên bản tóm tắt phiên bản đi kèm. Thứ hai, khả năng so sánh đa phiên bản: giao diện quản trị có thể vẽ biểu đồ Recall theo thời gian dựa trên dữ liệu các phiên bản đã chạy, qua đó phát hiện sớm xu hướng suy giảm chất lượng mô hình. Thứ ba, khả năng phục hồi: khi phát hiện một phiên bản mới gây ra vấn đề trong vận hành thực tế, người vận hành có thể quay trở lại bất kỳ phiên bản trước đó để khôi phục trạng thái ổn định.

Sự tách biệt giữa khu vực phục vụ – luôn duy trì duy nhất một phiên bản và phục vụ trực tiếp tăng dự đoán – và kho phiên bản – lưu lại lịch sử mọi lần tái huấn luyện – phản ánh nguyên tắc thiết kế kho mô hình tối giản: một nguồn duy nhất tin cậy cho pha phục vụ đi kèm với một kho lịch sử đầy đủ phục vụ phân tích và phục hồi.

CHƯƠNG 7. GIAO DIỆN VÀ DEMO

Chương này trình bày phần giao diện người dùng và các kịch bản demo của hệ thống đã được thiết kế ở Chương 6. Mục tiêu của giao diện là biến mô hình học máy thành một công cụ có thể được sử dụng trực tiếp bởi ba nhóm đối tượng chính: người dùng cuối cần đánh giá nguy cơ sức khỏe cá nhân, người vận hành chịu trách nhiệm cập nhật và giám sát mô hình, và người trình bày kết quả nghiên cứu trong các phiên bảo vệ học thuật.

7.1. Tổng quan giao diện

Giao diện được phát triển dưới dạng ứng dụng web tương tác, chạy trên trình duyệt mà không yêu cầu người dùng cài đặt thêm phần mềm chuyên dụng. Ứng dụng được tổ chức thành ba trang truy cập qua thanh điều hướng bên trái: trang Dự đoán dành cho người dùng cuối, trang Quản trị và Tái huấn luyện dành cho người vận hành, và trang So sánh – Demo phục vụ trình diễn kết quả thực nghiệm.

Bên dưới thanh điều hướng, hệ thống luôn hiển thị bảng tóm tắt về Champion đang phục vụ, gồm tên thuật toán, chỉ số Recall và tổng số mẫu đã sử dụng trong quá trình huấn luyện. Thông tin này giúp người dùng – ngay cả khi vừa truy cập – luôn biết phiên bản mô hình nào đang trả lời các yêu cầu dự đoán của mình.

7.2. Trang Dự đoán

Trang Dự đoán cho phép người dùng nhập 21 đặc trưng sức khỏe cá nhân và nhận về kết quả phân loại nguy cơ tiểu đường. Để tăng tính thân thiện với người dùng phổ thông, biểu mẫu được chia thành ba nhóm trực quan: nhóm Sức khỏe nền (huyết áp, cholesterol, BMI, tiền sử đột quỵ, tiền sử bệnh tim, khả năng đi lại và tự đánh giá sức khỏe tổng quát), nhóm Lối sống (tiền sử hút thuốc, vận động thể chất, thói quen ăn uống, mức tiêu thụ rượu, số ngày sức khỏe tinh thần và thể chất kém) và nhóm Nhân khẩu học và tiếp cận y tế (giới tính, nhóm tuổi, học vấn, thu nhập và tình trạng bảo hiểm).

Toàn bộ các trường nhị phân (Có / Không) được hiện thực dưới dạng nút chọn ngang để giảm thao tác nhấp chuột; các trường thang điểm rời rạc được trình bày kèm nhãn ngữ nghĩa (chẳng hạn “1 – Rất tốt” đến “5 – Rất kém” đối với tự đánh giá sức khỏe) thay vì chỉ hiển thị mã số nhằm tránh đòi hỏi người dùng tra mã theo quy ước BRFSS. Hình 7.1 cho thấy giao diện trang Dự đoán với các trường ở hai nhóm đầu tiên.

Deploy ⓘ

Điều hướng

Chọn trang:

- ☒ Dự đoán
- ☐ Quản trị & Tài huấn luyện
- ☐ So sánh & Demo

Mô hình hiện hành

Thuật toán: gradient_boosting

Recall: 0.8801

Số mẫu huấn luyện: 55245

Dự đoán nguy cơ mắc bệnh tiểu đường

Mô hình được huấn luyện trên bộ dữ liệu BRFS 2015 (50/50 split). Kết quả chỉ mang tính tham khảo, không thay thế chẩn đoán y khoa.

> Nạp nhanh case demo (tùy chọn)

1. Sức khỏe nền

Cao huyết áp

☒ Không ☐ Có

Đã kiểm tra cholesterol trong 5 năm gần đây

☐ Không ☒ Có

Bệnh tim hoặc đau tim

☒ Không ☐ Có

Chỉ số BMI (kg/m²)

25

Cholesterol cao

☒ Không ☐ Có

Đã từng bị đột quỵ

☒ Không ☐ Có

Khó đi lại / leo cầu thang

☒ Không ☐ Có

Tự đánh giá sức khỏe tổng quát

3 – Trung bình

2. Lối sống

Đã hút trên 100 điếu thuốc trong đời

☒ Không ☐ Có

Ăn trái cây ≥ 1 lần/ngày

☐ Không ☒ Có

Có vận động thể chất 30 ngày qua

☐ Không ☒ Có

Ăn rau xanh ≥ 1 lần/ngày

☐ Không ☒ Có

Hình 7.1. Giao diện trang Dự đoán – nhóm Sức khỏe nền và Lối sống.

Sau khi người dùng nhấn nút Dự đoán, hệ thống hiển thị ba thành phần kết quả: nhãn phân loại (Có / Không có nguy cơ) cùng xác suất tương ứng, thanh tiến trình thể hiện trực quan mức nguy cơ, và biểu đồ thể hiện top bảy đặc trưng có ảnh hưởng toàn cục lớn nhất tới mô hình. Hình 7.2 minh họa kết quả khi nạp kịch bản “Cao tuổi, nguy cơ cao”: hệ thống dự báo Có nguy cơ với xác suất xấp xỉ 91%, đồng thời liệt kê các yếu tố ảnh hưởng chính.

Deploy

Chọn trạng:

Dự đoán

Quản trị & Tái huấn luyện

Số sánh & Demo

Champion

Thuật toán: gradient_boosting

Recall: 0.8001

Số mẫu huấn luyện: 69057

Quản trị & Tái huấn luyện

ChampionUpload & Tái huấn luyệnLịch sử phiên bảnLập lịch tự động

Thông tin Champion

Thuật toán: gradient_boosting

Recall trên tập kiểm thử: 0.8001

Số mẫu: 69057

Thời điểm huấn luyện gần nhất: chưa ghi nhận

Bảng xếp hạng các mô hình ở lần retrain gần nhất:

	model	best_params	cv_recall	test_recall	test_precision	accuracy
0	gradient_boosting	{'model__learning_rate': 0.05, 'model__max_depth': 5, 'model__n_estimators': 200}	0.7982	0.8001	0.7317	0.7493
1	random_forest	{'model__max_depth': 10, 'model__min_samples_split': 2, 'model__n_estimators': 200}	0.7974	0.7972	0.728	0.7455
2	decision_tree	{'model__max_depth': 5, 'model__min_samples_split': 2}	0.8096	0.7729	0.7108	0.7247
3	logistic_regression	{'model__C': 0.1}	0.7706	0.7726	0.738	0.745
4	knn	{'model__n_neighbors': 11, 'model__weights': 'uniform'}	0.7638	0.7665	0.7133	0.7247

Hình 7.3. Trang Quản trị – Thẻ Champion với bảng xếp hạng năm mô hình.

Thẻ “Champion” trình bày tên thuật toán đang phục vụ, chỉ số Recall, tổng số mẫu huấn luyện và thời điểm huấn luyện gần nhất. Bên dưới là bảng đầy đủ kết quả của cả năm mô hình trong lần tái huấn luyện gần nhất, giúp người vận hành xác minh rằng mô hình đang phục vụ thực sự là tốt nhất theo tiêu chí Recall và đối chiếu chênh lệch với các mô hình còn lại.

Thẻ “Upload và Tái huấn luyện” là điểm tương tác chính giữa người vận hành và quy trình tái huấn luyện. Người vận hành có thể tải lên một hoặc nhiều tệp dữ liệu khảo sát mới, sau đó nhấn nút “Chạy tái huấn luyện” để kích hoạt toàn bộ chu trình từ kiểm tra cấu trúc, phát hiện trôi dữ liệu, huấn luyện năm mô hình cho đến so sánh Champion – Challenger. Trong suốt quá trình – thường kéo dài khoảng ba đến năm phút trên một máy tính cá nhân thông thường – ứng dụng hiển thị thanh tiến trình để người dùng theo dõi. Khi quá trình kết thúc, ứng dụng hiển thị hai thẻ chỉ số (Challenger và Champion trước đó), kết quả quyết định thăng cấp hoặc giữ nguyên cùng lý do, danh sách cột bị trôi (nếu có) và các vấn đề về cấu trúc dữ liệu (nếu có). Thẻ này cũng cung cấp một tùy chọn ép buộc thăng cấp dùng riêng cho mục đích kiểm thử.

Thẻ “Lịch sử phiên bản” hiển thị bảng tổng hợp mọi lần tái huấn luyện đã thực hiện, với các cột chính là thời điểm, tên Challenger, Recall của Challenger, tên Champion trước đó, Recall Champion, kết quả quyết định, tổng số mẫu và số mẫu được bổ sung. Bên dưới bảng là biểu đồ đường thể hiện diễn biến Recall của Challenger theo

thời gian – công cụ trực quan giúp phát hiện sớm các xu hướng suy giảm chất lượng hoặc dao động bất thường giữa các phiên bản liên tiếp.

Thẻ “Lập lịch tự động” quản lý tiến trình chạy nền, giúp chuyển đổi hệ thống từ vận hành thủ công sang chế độ tự động hóa khi có dòng dữ liệu bổ sung định kỳ. Theo cấu hình mặc định, cứ mỗi mười phút, hệ thống sẽ quét thư mục chờ và chỉ kích hoạt chu kỳ tái huấn luyện đầy đủ khi tổng số dòng mới đạt ngưỡng tối thiểu một trăm dòng. Cơ chế này giúp tối ưu tài nguyên tính toán, tránh việc tái huấn luyện quá thường xuyên trên những thay đổi dữ liệu nhỏ lẻ không đáng kể.

Giao diện của thẻ được chia làm ba khối thông tin chuyên biệt:

- Khối trạng thái thực tế: Hiển thị dải chỉ số về tình trạng hoạt động (Running/Stopped), chu kỳ quét, ngưỡng kích hoạt và tổng số dòng dữ liệu đang chờ để người vận hành biết liệu hệ thống đã đủ điều kiện tái huấn luyện hay chưa.
- Khối nhật ký vận hành: Cung cấp thông tin chi tiết về các mốc thời gian kiểm tra gần nhất/kế tiếp, thời điểm tái huấn luyện gần nhất do bộ lập lịch thực hiện kèm lý do cụ thể và danh sách các tệp đang nằm trong hàng đợi.
- Khối cấu hình: Cho phép người dùng tùy chỉnh linh hoạt chu kỳ kiểm tra và ngưỡng dòng; đồng thời cung cấp các nút chức năng để lưu thiết lập, dừng/chạy bộ lập lịch hoặc ép buộc một chu kỳ kiểm tra ngay lập tức.

Về mặt kỹ thuật, trạng thái của bộ lập lịch được lưu trữ độc lập để đảm bảo tính sẵn sàng sau khi khởi động lại mà không ảnh hưởng đến kho mô hình. Đặc biệt, hệ thống sử dụng cơ chế khóa loại trừ tương hỗ, tự động bỏ qua các lượt kiểm tra kế tiếp nếu một chu kỳ huấn luyện đang diễn ra, tránh tình trạng xung đột hoặc chồng lấn dữ liệu. Dù được kích hoạt tự động, quy trình này vẫn tuân thủ nghiêm ngặt các bước kiểm tra trôi dữ liệu và quy tắc thăng cấp Champion – Challenger tương tự như chế độ thủ công.

7.4. Trang So sánh và Demo

Trang này phục vụ mục đích trình diễn kết quả nghiên cứu, gồm ba khối nội dung: bảng xếp hạng năm mô hình, biểu đồ tầm quan trọng đặc trưng và ba kịch bản demo dựng sẵn.

Khối thứ nhất hiển thị toàn bộ chỉ số Recall, Precision, Accuracy và Recall qua kiểm định chéo của năm mô hình trong lần tái huấn luyện gần nhất, kèm theo biểu đồ

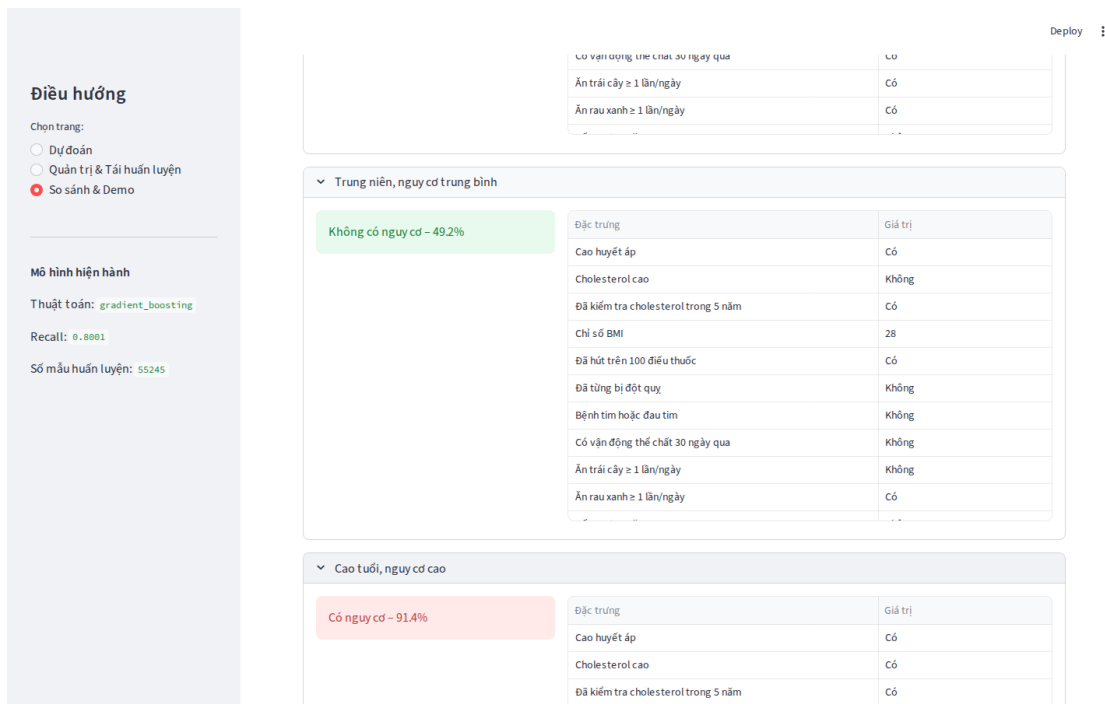
thanh so sánh trực quan giữa các mô hình theo ba chỉ số chính. Người xem có thể nhanh chóng nhận ra mô hình nào dẫn đầu ở từng tiêu chí và mức chênh lệch giữa các tiêu chí.

Khối thứ hai vẽ biểu đồ tầm quan trọng đặc trưng của Champion theo thứ tự giảm dần. Biểu đồ này cho phép người xem hiểu được mô hình đang dựa chủ yếu vào những đặc trưng nào để đưa ra quyết định phân loại, qua đó tăng tính minh bạch và khả năng giải thích lâm sàng cho hệ thống.

Khối thứ ba là ba kịch bản demo phản ánh ba phổ rủi ro điển hình:

- Khỏe mạnh – nguy cơ thấp: người trẻ, BMI bình thường, không có yếu tố nguy cơ về huyết áp – cholesterol, có vận động đều và chế độ ăn lành mạnh, tự đánh giá sức khỏe rất tốt.
- Trung niên – nguy cơ trung bình: người ở độ tuổi 50, BMI thừa cân nhẹ, có cao huyết áp, hút thuốc, ít vận động, tự đánh giá sức khỏe trung bình.
- Cao tuổi – nguy cơ cao: người ngoài 70 tuổi, BMI cao, hội tụ nhiều yếu tố nguy cơ gồm cao huyết áp, cholesterol cao, tiền sử bệnh tim, khó đi lại, sức khỏe tự đánh giá rất kém.

Hình 7.4 minh họa hai trong ba kịch bản đã được mở rộng để xem chi tiết: kịch bản trung niên cho kết quả “Không có nguy cơ” với xác suất 49,2%, kịch bản cao tuổi cho kết quả “Có nguy cơ” với xác suất 91,4%, đồng thời hiển thị bảng đầy đủ 21 đặc trưng đầu vào dưới dạng nhãn tiếng Việt thay cho mã số.



Hình 7.4. Trang So sánh và Demo với hai kịch bản demo được mở rộng.

Ba kịch bản trên đồng thời được sử dụng làm bộ kiểm thử nhanh cho mô hình: sau mỗi lần tái huấn luyện, người vận hành có thể đối chiếu kết quả của ba kịch bản này để đảm bảo mô hình mới vẫn cho ra dự đoán hợp lý ở cả ba phổ rủi ro.

7.5. Kịch bản triển khai và kiểm thử

Hệ thống được thiết kế để có thể triển khai và vận hành hoàn toàn trên một máy tính cá nhân, không yêu cầu cấu hình thêm máy chủ hay cơ sở dữ liệu phụ trợ. Sau khi khởi động, ứng dụng phục vụ trên một địa chỉ web cục bộ và sẵn sàng tiếp nhận yêu cầu dự đoán. Toàn bộ trạng thái mô hình, dữ liệu và lịch sử phiên bản được lưu trên hệ tệp cục bộ, qua đó đảm bảo tính tự chủ và khả năng tái lập trên các máy khác.

Hệ thống đã được kiểm thử qua ba kịch bản chính nhằm xác nhận đáp ứng các mục tiêu chức năng đặt ra ở Chương 1.

Kịch bản 1 – Dự đoán đơn lẻ: Người dùng truy cập trang Dự đoán, nạp nhanh kịch bản “Cao tuổi, nguy cơ cao” và bấm dự đoán. Kết quả trả về Có nguy cơ với xác suất xấp xỉ 91%; thời gian phản hồi đo được dưới một trăm mili giây nhờ cơ chế bộ nhớ đệm ở tầng phục vụ.

Kịch bản 2 – Tái huấn luyện không có dữ liệu mới: Người vận hành kích hoạt tái huấn luyện mà không tải thêm tệp nào. Hệ thống chạy lại quy trình trên dữ liệu nền, sinh

Challenger có Recall xấp xỉ Champion (do dùng cùng hạt giống ngẫu nhiên) và thắng cấp thành công. Kho phiên bản xuất hiện thêm một bản ghi mới với đầy đủ thông tin tóm tắt.

Kịch bản 3 – Tái huấn luyện với dữ liệu bổ sung có dấu hiệu trôi: Người vận hành tải lên một tệp khảo sát có cấu trúc đúng nhưng có giá trị BMI lệch trung bình hơn 15% so với hồ sơ nền. Hệ thống chạy tái huấn luyện bình thường, đồng thời hiển thị cảnh báo trôi dữ liệu trên cột BMI ở trang quản trị, kèm theo tỷ lệ chênh lệch cụ thể. Tùy thuộc vào Recall của Challenger, hệ thống tự động thăng cấp hoặc giữ nguyên Champion.

Ba kịch bản trên xác nhận rằng hệ thống đáp ứng đầy đủ các mục tiêu chức năng đã đặt ra ở Chương 1: dự đoán nguy cơ tiểu đường dựa trên 21 đặc trưng sức khỏe, hỗ trợ tái huấn luyện liên tục với dữ liệu bổ sung, kiểm soát chất lượng qua cơ chế Champion – Challenger, và minh bạch hóa cơ sở quyết định thông qua biểu đồ tầm quan trọng đặc trưng.

KẾT LUẬN

1. Kết quả đạt được

Sau quá trình nghiên cứu và thực hiện đề tài, nhóm đã xây dựng thành công hệ thống khai phá dữ liệu và dự đoán nguy cơ mắc bệnh tiểu đường dựa trên các kỹ thuật học máy. Hệ thống đã thực hiện đầy đủ quy trình từ phân tích dữ liệu, tiền xử lý, huấn luyện mô hình đến đánh giá và lưu trữ kết quả thực nghiệm.

Trong quá trình thực hiện, nhóm đã xây dựng được pipeline xử lý dữ liệu và huấn luyện mô hình tương đối hoàn chỉnh, bao gồm các bước đọc dữ liệu, kiểm tra chất lượng dữ liệu, chuẩn hóa dữ liệu, chia tập huấn luyện – kiểm thử, huấn luyện nhiều mô hình học máy và đánh giá kết quả tự động. Pipeline được thiết kế theo hướng có khả năng tái sử dụng và hỗ trợ tái huấn luyện khi có dữ liệu mới.

Đề tài đã tiến hành thực nghiệm trên bộ dữ liệu BRFSS 2015 Diabetes Health Indicators với khoảng hơn 70.000 mẫu dữ liệu sức khỏe thực tế. Nhiều thuật toán học máy đã được triển khai và so sánh như Logistic Regression, Decision Tree, Random Forest, Gradient Boosting và K-Nearest Neighbors (KNN). Kết quả thực nghiệm cho thấy các mô hình Ensemble Learning, đặc biệt là Gradient Boosting và XGBoost, đạt hiệu năng tốt trong bài toán dự đoán bệnh tiểu đường.

Mô hình tốt nhất đạt giá trị ROC-AUC xấp xỉ 0.83, cho thấy khả năng phân biệt tương đối hiệu quả giữa nhóm mắc bệnh và không mắc bệnh tiểu đường. Ngoài ra, các chỉ số Accuracy, Recall và F1-score cũng đạt kết quả ổn định, phù hợp với đặc thù của bài toán dữ liệu y tế.

Bên cạnh đó, hệ thống còn hỗ trợ lưu trữ mô hình, metadata và báo cáo đánh giá nhằm phục vụ cho quá trình theo dõi, tái sử dụng và mở rộng hệ thống trong tương lai.

2. Hạn chế

Mặc dù đạt được các kết quả khả quan, đề tài vẫn còn tồn tại một số hạn chế nhất định.

Thứ nhất, hệ thống hiện mới hoạt động theo cơ chế xử lý offline và batch-based, chưa hỗ trợ xử lý dữ liệu thời gian thực (real-time processing). Do đó, khả năng ứng dụng trực tiếp trong các hệ thống giám sát y tế thời gian thực vẫn còn hạn chế.

Thứ hai, dữ liệu sử dụng trong nghiên cứu là dữ liệu khảo sát có sẵn từ bộ BRFSS 2015 nên chưa phản ánh dữ liệu sức khỏe liên tục theo thời gian thực từ người dùng. Hệ thống hiện chưa tích hợp dữ liệu từ các thiết bị IoT hoặc wearable như đồng hồ thông minh, cảm biến sức khỏe hay thiết bị theo dõi vận động.

Ngoài ra, đề tài mới tập trung vào các mô hình Machine Learning truyền thống và chưa nghiên cứu các phương pháp Deep Learning hoặc các mô hình học sâu hiện đại. Việc chưa triển khai các kỹ thuật nâng cao có thể làm hạn chế khả năng khai thác các mối quan hệ phi tuyến phức tạp trong dữ liệu.

Bên cạnh đó, hệ thống hiện chưa được triển khai trên môi trường cloud hoặc production thực tế. Các chức năng quản lý mô hình, giám sát hệ thống và tự động mở rộng tài nguyên vẫn chưa được tích hợp đầy đủ.

3. Hướng phát triển

Trong tương lai, đề tài có thể được mở rộng theo nhiều hướng nhằm nâng cao khả năng ứng dụng thực tế và hiệu năng của hệ thống.

Một trong những hướng phát triển quan trọng là xây dựng giao diện web hoặc web application nhằm hỗ trợ người dùng nhập dữ liệu sức khỏe và nhận kết quả dự đoán trực quan. Việc triển khai giao diện người dùng sẽ giúp hệ thống có tính ứng dụng cao hơn trong thực tế.

Ngoài ra, hệ thống có thể được tích hợp thêm dữ liệu từ các thiết bị IoT và wearable như smartwatch, cảm biến nhịp tim, cảm biến vận động hoặc thiết bị theo dõi sức khỏe cá nhân. Điều này sẽ giúp mô hình có khả năng phân tích dữ liệu theo thời gian thực và nâng cao độ chính xác dự đoán.

Đề tài cũng có thể mở rộng theo hướng áp dụng Federated Learning nhằm đảm bảo quyền riêng tư dữ liệu y tế trong quá trình huấn luyện mô hình phân tán giữa nhiều thiết bị hoặc cơ sở y tế khác nhau.

Bên cạnh đó, Reinforcement Learning có thể được nghiên cứu để xây dựng hệ thống hỗ trợ chăm sóc sức khỏe cá nhân hóa (Personalized Healthcare), trong đó mô hình có khả năng đưa ra các khuyến nghị phù hợp với từng người dùng dựa trên trạng thái sức khỏe và hành vi sinh hoạt.

Cuối cùng, hệ thống có thể được tích hợp các công nghệ AutoML và MLOps nhằm tự động hóa quá trình lựa chọn mô hình, tối ưu siêu tham số, triển khai mô hình và giám sát hiệu năng trong môi trường thực tế. Điều này sẽ giúp nâng cao khả năng mở rộng, bảo trì và vận hành hệ thống trong dài hạn.